DATA SCIENCE / QUICK REFERENCE

# Pandas

Seleção, limpeza e transformação tabular

## LEITURA E INSPEÇÃO

**Importar**
```
import pandas as pd
```

**CSV**
```
pd.read_csv("arquivo.csv", sep=",")
```

**Excel**
```
pd.read_excel("arquivo.xlsx")
```

**Início**
```
df.head()
```

**Estrutura**
```
df.info() / df.dtypes
```

**Resumo**
```
df.describe()
```

## SELEÇÃO

**Rótulos**
```
df.loc[linhas, colunas]
```

**Posições**
```
df.iloc[0:5, 1:3]
```

**Filtro**
```
df.loc[df["valor"] > 0]
```

**Conjunção**
```
(cond1) & (cond2)
```

**Colunas**
```
df[["a", "b"]]
```

## LIMPEZA E TIPOS

**Ausentes**
```
df.isna().sum()
```

**Preencher**
```
df["x"].fillna(0)
```

**Remover**
```
df.dropna(subset=["x"])
```

**Duplicatas**
```
df.drop_duplicates()
```

**Número**
```
pd.to_numeric(s, errors="coerce")
```

**Datas**
```
pd.to_datetime(s, errors="coerce")
```

## TRANSFORMAR

**Criar coluna**
```
df.assign(total=df.x * df.y)
```

**Ordenar**
```
df.sort_values("total")
```

**Agrupar**
```
df.groupby("grupo")["x"].sum()
```

**Mapear**
```
df["x"].map(mapa)
```

## JUNÇÕES E AUDITORIA

**Merge**
```
df1.merge(df2, on="id")
```

**Cardinalidade**
```
validate="many_to_one"
```

**Origem**
```
indicator=True
```

**Contar antes/depois**
```
len(df) / len(resultado)
```

**Vazamento**
```
Evitar imputar antes da divisão
```

## GRAVAR

**CSV**
```
df.to_csv("saida.csv", index=False)
```

**Excel**
```
df.to_excel("saida.xlsx", index=False)
```

**Dependência XLSX**
```
openpyxl
```

**Segurança**
```
Cuidado com sobrescrita
```