GUIA TÉCNICO

Análise exploratória de dados

Qualidade, distribuições, relações e indicadores com cobertura explícita

Propósito — conectar decisões metodológicas, exemplos reproduzíveis e interpretação responsável. Material complementar aos notebooks revisados, não substitui a execução no JupyterLab.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

ROTEIRO DO DOCUMENTO

1. Definir a pergunta e a unidade de observação
2. Auditoria de esquema, ausências e duplicatas
3. Distribuições, posição e dispersão
4. Relações, estratificação e confundimento
5. Indicadores derivados com denominadores auditáveis
6. Transformar exploração em narrativa técnica

01 Definir a pergunta e a unidade de observação

EDA não é uma coleção de gráficos. É um ciclo de formulação de perguntas, reconhecimento do processo de coleta, auditoria do conjunto de dados e interpretação provisória de padrões. Antes de calcular, identifique o que uma linha representa: no dataset de vendas, cada linha descreve uma transação; uma região, um produto ou um dia podem aparecer várias vezes. Essa definição orienta a identificação de duplicatas, a escolha dos denominadores e a agregação. Uma tabela pode estar tecnicamente íntegra e ainda assim não representar a população de interesse.

Ponto de atenção

Registre período, origem, universo pretendido, granularidade, chaves, unidades físicas e limitações. Uma contagem de linhas não corresponde automaticamente a clientes únicos, e uma correlação observada não demonstra causalidade.

02 Auditoria de esquema, ausências e duplicatas

A inspeção inicial deve diferenciar erros de representação (tipo de dado incorreto), erros de domínio (quantidades negativas sem justificativa), ausência de medição e repetição legítima. `duplicated()` procura linhas idênticas; duplicação de chave exige uma definição de chave de negócio. A completude pode ser calculada por campo ou por combinação de campos indispensáveis.

Ponto de atenção

Não substitua automaticamente `NaN` por zero. Preço desconhecido não significa produto gratuito. Uma aparente duplicação pode ser uma segunda compra válida.

03 Distribuições, posição e dispersão

A média responde ao valor médio aritmético, mas reage intensamente a extremos. A mediana descreve o ponto central em dados ordenados. Quartis, IQR, amplitude e desvio-padrão revelam características diferentes. Histogramas dependem da escolha de intervalos; boxplots resumem quartis e sinalizam pontos a investigar. Antes de remover outliers, inspecione a plausibilidade e o processo de registro.

Ponto de atenção

O critério de 1,5 × IQR identifica observações incomuns sob uma regra exploratória, não dados obrigatoriamente incorretos.

04 Relações, estratificação e confundimento

Um scatterplot ajuda a visualizar associações entre preço e unidades, porém a nuvem de pontos não fornece sozinha evidência de efeito causal. Pode existir diferença de escala por produto ou canal: uma associação agregada pode mudar quando analisada por grupo. Observe amostra, valores ausentes, variabilidade e restrições de medição. Compare grupos em condições semelhantes sempre que possível.

Ponto de atenção

Evite rótulos como ‘o preço reduziu as vendas’ quando o dataset permite apenas descrever uma associação.

05 Indicadores derivados com denominadores auditáveis

A receita observável por transação é `unidades * preco_unitario`. Com preço ausente, a receita daquele registro é desconhecida. Somar os valores conhecidos e chamá-los de ‘receita total’ omite a perda de cobertura. Publique lado a lado a soma conhecida, o número de registros elegíveis e a porcentagem com preço válido. Uma análise reproduzível conserva o dado bruto e computa indicadores em cópia de trabalho.

Ponto de atenção

Com cobertura diferente entre produtos, o ranking de receita conhecida não necessariamente representa o ranking de faturamento real.

06 Transformar exploração em narrativa técnica

Uma síntese de EDA deve responder à pergunta formulada, mostrar as medidas relevantes e declarar o grau de confiança apropriado. Diferencie achado (o que foi calculado), hipótese (explicação possível) e decisão (ação proposta). Inclua o período, a cobertura e a evidência que permitiria refutar a hipótese. Dados sintéticos demonstram procedimentos, não resultados de mercado.

Ponto de atenção

Uma conclusão útil não precisa ser forte: ‘nos registros observados, o produto X possui mais unidades, com cobertura de preço Y%’ é mais auditável do que ‘X é o melhor produto’.

Decisões avançadas e testes de robustez

Os tópicos seguintes aprofundam decisões que o código sozinho não explica. Use-os ao adaptar as demonstrações a bases diferentes.

Contrato de uma EDA auditável

Descreva antes de executar: qual registro representa uma transação, qual período está coberto, quais colunas são medidas, quais são dimensões e qual ausência compromete cada métrica. Uma política operacional pode marcar preço ausente como motivo para excluir apenas o cálculo monetário, mantendo a transação nos totais de unidades. Inclua explicitamente essa distinção no relatório, evitando a falsa impressão de que todas as métricas têm o mesmo universo.

Sensibilidade a exclusões e valores extremos

Execute o indicador com e sem registros sinalizados pelo IQR, preservando ambas as versões. Se a diferença mudar a conclusão, investigue as causas antes de eliminar os registros. Compare média e mediana por grupo; prefira descrever a distribuição com mais de uma estatística quando houver assimetria. A robustez de uma conclusão aumenta quando escolhas razoáveis de limpeza não a invertem.

Amostragem e limites de inferência

Dados de demonstração não representam uma população real. Mesmo em dados observacionais verdadeiros, uma amostra de conveniência pode excluir segmentos importantes. A EDA deve registrar quem entrou, quem ficou de fora e se a coleta mudou ao longo do período. Sem hipótese de amostragem adequada, intervalos e correlações descrevem a base analisada, não autorizam extrapolação automática.

Checklist operacional

Valide dtypes e chaves; compute nulos por campo; identifique duplicatas pela granularidade de negócio; cheque domínios; examine distribuições e estratos; registre denominadores de cada indicador; reúna limitações. Só depois disso selecione gráficos para comunicar os achados. A análise deve poder ser refeita quando houver uma nova versão do CSV.

Exemplo reproduzível

Execute na pasta da disciplina, com os quatro CSVs originais em datasets/. O código abaixo é uma demonstração complementar e não altera os arquivos de entrada.

```
from pathlib import Path
import pandas as pd
vendas = pd.read_csv(Path('datasets') / 'vendas_exemplo.csv')
audit = pd.DataFrame({'tipo': vendas.dtypes.astype(str),
                      'ausentes': vendas.isna().sum(),
                      'completude_pct': (1 - vendas.isna().mean()).mul(100).round(1)})
vendas['receita'] = vendas['unidades'] * vendas['preco_unitario']
resumo = vendas.groupby('produto').agg(
    receita_conhecida=('receita', lambda s: s.sum(min_count=1)),
    registros=('produto', 'size'),
    precos_validos=('preco_unitario', 'count'))
resumo['cobertura_preco_pct'] = 100 * resumo.precos_validos / resumo.registros
print(audit); print(resumo.round(1))
```

Como interpretar o resultado

Confira se as medidas calculadas correspondem à pergunta, se há observações ausentes e se as somas ou taxas podem ser comparadas. Os valores resultantes pertencem exclusivamente às bases sintéticas de ensino.

Exercícios e resoluções comentadas

Exercício 1 — Por que uma chave repetida não prova duplicidade?

Resolução comentada: Porque a chave só é única se representar a granularidade esperada; um cliente pode realizar várias transações válidas.

Exercício 2 — Duas categorias têm receitas observadas semelhantes e coberturas distintas. O que relatar?

Resolução comentada: A soma conhecida e a cobertura de cada categoria, sem inferir o total desconhecido.

Exercício 3 — O que concluir sobre outliers após o boxplot?

Resolução comentada: Apenas que existem candidatos à inspeção; exclusão depende de critérios substantivos.

Checklist antes de publicar uma conclusão

- Pergunta, período e unidade observacional declarados.
- Datasets originais preservados; saídas apenas em outputs/.
- Ausências, filtros, chaves e denominadores explicitados.

- Cálculos e gráficos vinculados a uma interpretação verificável.
- Limitações dos dados sintéticos e das inferências declaradas.

Referências para continuidade

Consulte a documentação oficial de Pandas, NumPy, Matplotlib, Seaborn, Plotly, Bokeh e Altair conforme a biblioteca usada em cada notebook. As versões instaladas devem ser verificadas no próprio ambiente; requirements.txt fornece requisitos mínimos, não um lockfile. Licenciamento e identidade Material didático original preparado para o acervo EP, com exemplos derivados dos dados de demonstração do pacote. Licenças de código e conteúdo são mantidas na raiz do repositório.