GUIA TÉCNICO EP / DISCIPLINA 02

Agrupamentos e análise comparativa

Métricas, ponderações, tabelas dinâmicas e denominadores

Objetivo: conectar decisões metodológicas, exemplos reproduzíveis e interpretação responsável. Material complementar aos notebooks revisados, não substitui a execução no JupyterLab.

MAPA DE ESTUDO

01 A unidade da pergunta define a agregação

02 Agrupar sem esconder valores ausentes

03 Médias ponderadas e falácia das médias de médias

04 Pivot tables, crosstab e percentuais

05 Ranking, comparabilidade e granularidade

06 Validações cruzadas e apresentação

Base didática: notebooks 01–07 e datasets sintéticos da disciplina. O conteúdo foi ampliado editorialmente para consulta independente.

01 A unidade da pergunta define a agregação

Antes de agrupar, defina a grandeza de interesse: quantidade de registros, soma de unidades, média por transação ou percentual de casos. `size()` conta linhas, inclusive quando um campo de interesse é ausente; `count()` conta valores válidos daquele campo. `sum()`, `mean()` e `nunique()` respondem a perguntas distintas. Uma métrica só é interpretável quando seu denominador é conhecido.

Ponto de atenção

‘Melhor desempenho’ não é uma métrica. Declare ‘maior volume de unidades’ ou ‘menor tempo médio entre casos válidos’.

02 Agrupar sem esconder valores ausentes

`groupby(..., dropna=False)` conserva grupos com categoria ausente, quando essa distinção é relevante. Ao calcular taxas, explicite o número de casos válidos, o universo elegível e o tratamento de respostas desconhecidas. Uma categoria pode aparentar taxa de resolução alta se os casos não respondidos forem excluídos seletivamente. Inspecione frequência, cobertura e dispersão antes de ordenar rankings.

Ponto de atenção

Não confunda percentual sobre respondentes com percentual sobre todos os registros.

03 Médias ponderadas e falácia das médias de médias

Se o grupo A tem 100 observações e o B tem 5, as médias dos dois grupos não têm o mesmo peso no total observado. A média global por observação é a soma de cada média multiplicada pelo número de observações válidas, dividida pelo total dessas observações. Taxas exigem o mesmo cuidado: o denominador pode ser clientes atendidos, transações ou chamados elegíveis.

Ponto de atenção

Uma média simples de taxas de grupos só corresponde à taxa global sob condições específicas, como denominadores iguais.

04 Pivot tables, crosstab e percentuais

Tabelas dinâmicas cruzam dimensões e facilitam a leitura de matrizes. `pivot_table` calcula medidas numéricas; `crosstab` resume frequência ou porcentagens. `fill_value=0` pode ser legítimo para combinações sem ocorrências, mas não para medições desconhecidas. Verifique totais por linha e coluna e identifique categorias sem observações.

Ponto de atenção

Uma célula vazia pode significar ‘não houve transações’ ou ‘não temos dados’; o relatório deve distinguir as duas situações.

05 Ranking, comparabilidade e granularidade

Rankings são vulneráveis a grupos de tamanhos muito diferentes e a dados faltantes. Compare a taxa somente quando existe exposição comparável e estimativa suficientemente sustentada. Estratifique por canal, produto ou região quando variáveis de composição podem alterar a leitura. O conjunto sintético de reclamações ilustra o contraste entre quantidade de casos e taxa de resolução.

Ponto de atenção

Sem base externa de clientes ou transações, não é possível converter contagem de reclamações em taxa por cliente.

06 Validações cruzadas e apresentação

Compare a soma dos subtotais ao total bruto da mesma métrica e verifique se filtros, duplicações ou ausências explicam as diferenças. Ao publicar uma tabela agregada, inclua nomes explícitos, unidades, período, método de cálculo, cobertura e uma observação sobre limitações. Armazene cálculos intermediários suficientes para auditoria sem poluir a tabela final.

Ponto de atenção

Boas tabelas não substituem a interpretação: explique o que o indicador mede e o que ele não permite afirmar.

Decisões avançadas e testes de robustez

Os tópicos seguintes aprofundam decisões que o código sozinho não explica. Use-os ao adaptar as demonstrações a bases diferentes.

Escolha do denominador como decisão de negócio

Para calcular a proporção de reclamações resolvidas entre casos com resposta conhecida, divida o número de resolvidas pelo número com status válido. Para uma taxa por demanda recebida, o denominador pode ser todos os casos; mas ausências no status exigem política explícita. Essas medidas podem ser diferentes e são igualmente legítimas para perguntas distintas. Escreva sempre no título da tabela que população está sendo considerada.

Efeito da composição de grupos

Um canal pode parecer mais rápido porque recebe reclamações simples e outro mais lento porque lida com casos complexos. A diferença agregada não identifica desempenho independente do tipo de caso. Estratifique por categoria ou outra variável pertinente, mostre tamanho dos subgrupos e procure padrões estáveis. Esse exercício reduz o risco de atribuir a uma equipe um efeito que resulta da distribuição dos casos.

Reconciliação entre subtotal e total

Uma tabela de produtos por canal precisa reconciliar a soma de unidades à soma obtida antes do agrupamento, desde que não haja filtros distintos. Se houver diferença, verifique categorias nulas, exclusões, multiplicações em junções ou transformação de unidades. Para medidas não aditivas, como média e taxa, reconciliar exige numeradores e denominadores, não somar percentuais.

Apresentar ranking com limites

Uma ordenação deve incluir volume de suporte, cobertura e descrição da métrica. Um grupo com apenas dois registros pode liderar uma taxa e ainda ser inadequado para a conclusão desejada. Informe filtros e período, e evite fórmulas universais como “grupo mais eficiente” sem avaliação de custo, dificuldade e qualidade. O ranking é resultado de uma regra explícita, não atributo absoluto do grupo.

Exemplo reproduzível

Execute na pasta da disciplina, com os quatro CSVs originais em datasets/. O código abaixo é uma demonstração complementar e não altera os arquivos de entrada.

```
import pandas as pd
ex = pd.DataFrame({'grupo': ['A','A','A','B'], 'nota': [5.,5.,5.,1.]})
por_grupo = ex.groupby('grupo')['nota'].agg(media='mean', n='count')
media_ponderada = (por_grupo['media'] * por_grupo['n']).sum() / por_grupo['n'].sum()
print('Média global:', ex['nota'].mean())
print('Média simples das médias:', por_grupo['media'].mean())
print('Média ponderada:', media_ponderada)
assert media_ponderada == ex['nota'].mean()
```

Como interpretar o resultado

Confira se as medidas calculadas correspondem à pergunta, se há observações ausentes e se as somas ou taxas podem ser comparadas. Os valores resultantes pertencem exclusivamente às bases sintéticas de ensino.

Exercícios e resoluções comentadas

Exercício 1 — Por que size e count podem diferir?

Resolução comentada: size conta registros; count ignora valores ausentes no campo agregado.

Exercício 2 — Quando preencher célula de pivot com zero é arriscado?

Resolução comentada: Quando o vazio significa dado não observado, e não ausência real de ocorrências.

Exercício 3 — Qual denominador exige uma taxa de reclamações por cliente?

Resolução comentada: O número de clientes ou uma exposição equivalente, que não é fornecida automaticamente pela tabela de reclamações.

Checklist antes de publicar uma conclusão

- Pergunta, período e unidade observacional declarados.
- Datasets originais preservados; saídas apenas em outputs/.
- Ausências, filtros, chaves e denominadores explicitados.
- Cálculos e gráficos vinculados a uma interpretação verificável.
- Limitações dos dados sintéticos e das inferências declaradas.

Referências para continuidade

Consulte a documentação oficial de Pandas, NumPy, Matplotlib, Seaborn, Plotly, Bokeh e Altair conforme a biblioteca usada em cada notebook. As versões instaladas devem ser verificadas no próprio ambiente; requirements.txt fornece requisitos mínimos, não um lockfile.

Licenciamento e identidade

Material didático original preparado para o acervo EP, com exemplos derivados dos dados de demonstração do pacote. Licenças de código e conteúdo são mantidas na raiz do repositório.