GUIA TÉCNICO

Matplotlib e Seaborn

Integridade gráfica, distribuição, associação e acessibilidade

Propósito — conectar decisões metodológicas, exemplos reproduzíveis e interpretação responsável. Material complementar aos notebooks revisados, não substitui a execução no JupyterLab.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

ROTEIRO DO DOCUMENTO

1. Começar pela pergunta, não pelo gráfico
2. Modelo de objetos do Matplotlib
3. Seaborn e comparação de distribuições
4. Escalas, cores e efeitos perceptivos
5. Incerteza e barras de erro
6. Exportação, legendas e acessibilidade

01 Começar pela pergunta, não pelo gráfico

A seleção do gráfico depende de dado, tarefa e público: barras para categorias, linhas para variações em ordem temporal, histogramas e boxplots para distribuições, dispersão para associações. Um bom gráfico responde a uma pergunta identificável, não exibe toda a informação disponível. A tabela de vendas contém dimensões categóricas e medidas numéricas; o dataset de clima é adequado a exemplos temporais.

Ponto de atenção

Gráficos bonitos podem ser analiticamente incorretos quando usam a métrica errada, categoria mal definida ou subconjunto sem transparência.

02 Modelo de objetos do Matplotlib

Matplotlib distingue a figura (`Figure`) e a região gráfica (`Axes`). Criar `fig, ax = plt.subplots()` facilita controlar títulos, rótulos, escalas, limites e legendas. O método `ax.set(...)` reúne configurações; `fig.tight_layout()` ajuda a evitar cortes e `fig.savefig(...)` exporta com resolução e formatos apropriados. Seaborn recebe `ax` para combinar gramática estatística e controle visual.

Ponto de atenção

Para um gráfico reproduzível, não dependa implicitamente do último eixo ativo quando estiver organizando múltiplos painéis.

03 Seaborn e comparação de distribuições

Boxplots condensam posição, dispersão e pontos extremos, mas não mostram exatamente a forma de todas as distribuições. Histogramas dependem de bins; um violinplot oferece outra leitura da densidade, com riscos em amostras pequenas. `sns.scatterplot` permite codificar grupos por cor, estilo ou tamanho, desde que a legenda seja compreensível. Facetas ajudam a evitar mistura de populações muito distintas.

Ponto de atenção

Evite concluir que dois grupos têm o mesmo comportamento apenas porque suas médias são parecidas.

04 Escalas, cores e efeitos perceptivos

Barras dependem de comprimento em relação à linha de base; iniciar o eixo num valor alto pode amplificar diferenças pequenas. A escolha da escala em linhas deve ser informada e coerente com a pergunta. Paletas precisam distinguir categorias sem depender só da cor; utilize padrões, rótulos ou outras pistas quando adequado. Não use arco-íris arbitrário para uma medida ordenada quando existe escala perceptual melhor.

Ponto de atenção

Inclua unidade, período, fonte e observação quando houver filtros ou dados desconhecidos.

05 Incerteza e barras de erro

Desvio-padrão mede a dispersão observada; erro-padrão descreve a incerteza da estimativa da média sob hipóteses; intervalo de confiança expressa uma faixa associada a um procedimento inferencial. Não são conceitos intercambiáveis. Uma barra de erro deve indicar qual medida foi calculada. Em dados sintéticos ou em amostras pequenas, não confunda a visualização com evidência de representatividade.

Ponto de atenção

Nunca rotule genericamente como ‘intervalo’ sem explicar o cálculo e a população de referência.

06 Exportação, legendas e acessibilidade

Um gráfico publicado em portfólio precisa manter legibilidade fora do notebook. Escolha tamanho de figura, DPI, formato, cores, títulos, rótulos e margens com base no destino. Em relatórios, acompanhe a imagem de um resumo textual, especialmente para leituras assistivas. Use `bbox_inches='tight'` com cuidado para não cortar elementos e conserve uma versão baseada em dados para auditoria.

Ponto de atenção

As decisões de visualização fazem parte do método e devem ser documentadas junto com as transformações que alimentam o gráfico.

Decisões avançadas e testes de robustez

Os tópicos seguintes aprofundam decisões que o código sozinho não explica. Use-os ao adaptar as demonstrações a bases diferentes.

Auditoria de escala e origem

Verifique a linha de base em barras, as unidades, os limites escolhidos e qualquer transformação logarítmica. Um gráfico pode estar matematicamente correto e visualmente tendencioso. A escala precisa atender à pergunta sem exagerar diferenças ou esconder valores. Em múltiplos painéis, eixos independentes exigem informação clara; a comparação visual direta só é segura quando as escalas são compatíveis.

Distribuição além da média

Para explicar uma variável contínua, compare histogramas com o mesmo conjunto de bins e boxplots por categoria. Uma média próxima pode encobrir dispersões muito diferentes. Em grupos pequenos, uma curva de densidade suavizada pode sugerir estrutura que os dados não sustentam. Avalie a quantidade de observações antes de escolher estatísticas e marcas visuais mais sofisticadas.

Incerteza: o que a marca comunica

Desvio padrão resume dispersão amostral, erro padrão da média depende do tamanho amostral e intervalos de confiança dependem de um método inferencial e de hipóteses. Eles não são substitutos. Se um Seaborn estimar uma faixa automaticamente, documente o método e a versão da biblioteca. Em casos sintéticos e observacionais, mostrar um intervalo não garante validade externa nem causalidade.

Exportar e verificar como leitor

Exporte PNG em resolução adequada e SVG quando precisar de vetor. Abra o arquivo fora do JupyterLab para testar fontes, margens, eixos e legendas. A combinação entre título, subtítulo ou texto de apoio deve responder o quê, quando e com qual população. Para acessibilidade, use contraste suficiente, rótulos textuais e uma frase descritiva que preserve o achado mesmo quando o gráfico não é visto.

Exemplo reproduzível

Execute na pasta da disciplina, com os quatro CSVs originais em datasets/. O código abaixo é uma demonstração complementar e não altera os arquivos de entrada.

```
from pathlib import Path
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
vendas = pd.read_csv(Path('datasets') / 'vendas_exemplo.csv')
resumo = vendas.groupby('produto')['unidades'].sum().sort_values()
fig, ax = plt.subplots(figsize=(8, 4))
resumo.plot.barh(ax=ax)
ax.set(title='Unidades por produto — dados sintéticos',
       xlabel='Unidades vendidas', ylabel='Produto')
ax.grid(axis='x', alpha=.2)
fig.tight_layout()
Path('outputs').mkdir(exist_ok=True)
fig.savefig(Path('outputs') / 'unidades_por_produto.png', dpi=160)
plt.show()
```

Como interpretar o resultado

Confira se as medidas calculadas correspondem à pergunta, se há observações ausentes e se as somas ou taxas podem ser comparadas. Os valores resultantes pertencem exclusivamente às bases sintéticas de ensino.

Exercícios e resoluções comentadas

Exercício 1 — Quando a linha é preferível às barras?

Resolução comentada: Quando a ordem temporal e a continuidade entre observações são essenciais à pergunta.

Exercício 2 — O que uma barra de erro deve informar?

Resolução comentada: Se representa SD, SE ou intervalo de confiança, além do procedimento de cálculo.

Exercício 3 — Qual problema de truncar o eixo de barras?

Resolução comentada: O comprimento das barras deixa de refletir proporcionalmente o valor a partir de uma base comum zero.

Checklist antes de publicar uma conclusão

- Pergunta, período e unidade observacional declarados.
- Datasets originais preservados; saídas apenas em outputs/.
- Ausências, filtros, chaves e denominadores explicitados.

- Cálculos e gráficos vinculados a uma interpretação verificável.
- Limitações dos dados sintéticos e das inferências declaradas.

Referências para continuidade

Consulte a documentação oficial de Pandas, NumPy, Matplotlib, Seaborn, Plotly, Bokeh e Altair conforme a biblioteca usada em cada notebook. As versões instaladas devem ser verificadas no próprio ambiente; requirements.txt fornece requisitos mínimos, não um lockfile. Licenciamento e identidade Material didático original preparado para o acervo EP, com exemplos derivados dos dados de demonstração do pacote. Licenças de código e conteúdo são mantidas na raiz do repositório.