Amostragem e experimentos

Amostragem · Sorteio Sem Reposição

AMOSTRAGEM

Sorteio sem reposição

```
import numpy as np
rng = np.random.default_rng(42)
idx = rng.choice(len(df), 100,
                 replace=False)
```

n deve ser <= tamanho da população.

Amostra pandas

```
amostra = df.sample(n=100,
    random_state=42)
```

Amostragem uniforme de linhas.

Estratificar

```
amostra = df.groupby("grupo",
    group_keys=False).sample(frac=.2,
    random_state=42)
```

Verifique estratos muito pequenos.

EXPERIMENTO A/B

Atribuir tratamento

```
grupo = rng.choice(["A","B"],
    size=len(df), replace=True)
```

Registre unidade de randomização.

Resumo de efeito

```
media = df.groupby("grupo")["y"].mean()
efeito = media["B"] - media["A"]
```

Diferença de médias não basta.

Teste independente

```
from scipy.stats import ttest_ind
stat, p = ttest_ind(y_a, y_b,
    equal_var=False)
```

Welch: variâncias não iguais.

CONTROLE DE QUALIDADE

Proporção por grupo

```
pd.crosstab(df["grupo"],
    df["tratamento"], normalize="index")
```

Detecte desequilíbrio evidente.

Bootstrap de diferença

```
boots = [rng.choice(y_b,len(y_b),True).mean()
 - rng.choice(y_a,len(y_a),True).mean()
 for _ in range(1000)]
print(np.quantile(boots,[.025,.975]))
```

Assume observações independentes.

Atenção

```
n = len(df)
print("N =", n)
```

Seleção enviesada não se cura com n.

Receitas de consulta: adapte dados, colunas, credenciais e versões. Execute somente em ambientes autorizados.