Estatística descritiva e dispersão

Medidas Centrais · Média, Mediana E Moda

MEDIDAS CENTRAIS

Média, mediana e moda

```
import pandas as pd
s = df["valor"].dropna()
print(s.mean(), s.median())
print(s.mode().tolist())
```

Média sofre com valores extremos.

Quartis e amplitude

```
print(s.quantile([.25, .5, .75]))
print(s.max() - s.min())
```

Q3 - Q1 é o IQR.

DISPERSÃO

Desvio e variância

```
print(s.std(ddof=1))
print(s.var(ddof=1))
```

ddof=1 para amostra.

Coeficiente variação

```
cv = s.std() / s.mean()
print(cv)
```

Requer média não nula; use com critério.

Faixa IQR

```
q1, q3 = s.quantile([.25,.75])
iqr = q3 - q1
out = s[(s < q1-1.5*iqr) |
        (s > q3+1.5*iqr)]
```

Outlier não é erro automaticamente.

VISUALIZAR / CUIDADOS

Histograma

```
import matplotlib.pyplot as plt
s.plot.hist(bins=15)
plt.show()
```

Compare diferentes números de bins.

Boxplot

```
s.plot.box()
plt.show()
```

Considere escalas e unidades.

Por grupo

```
df.groupby("grupo")["valor"].agg(
    ["mean", "std", "count"])
```

Compare tamanho de grupos.