CHEAT SHEET / MÓDULO 01

Fundamentos e Organizacao de Dados

CONCEITOS E DECISÕES

- 1. População, unidade e variáveis
- 2. Frequências e valores ausentes
- 3. Tabelas de dupla entrada
- 4. Agrupamento em classes
- 5. Escolha dos gráficos
- Amostra, população e validade externa: Uma tabela pode ser descrita corretamente e ainda assim não representar a população de interesse. Antes de calcular proporções, defina quem pode integrar a base, em que período e quais unidades ficaram fora. A frequência relativa calculada com uma amostra de conveniência não é, por si só, uma estimativa sem viés da frequência populacional.

COMANDOS, FÓRMULAS E MÉTODOS

- df.shape
- df.info()
- s.value_counts(dropna=False)
- pd.crosstab(a,b)
- pd.cut(x,bins=...)
- ax.hist(...)
- ax.bar(...).
- Escalas de mensuração e operações válidas: Variáveis nominais permitem comparação de igualdade e contagem; ordinais possuem ordem, mas não distâncias necessariamente equivalentes. Uma escala numérica pode ser codificação de uma categoria e não uma grandeza quantitativa. A classificação correta determina se médias, desvios e histogramas são interpretáveis.

CUIDADOS DE INTERPRETAÇÃO

- Evite interpretar IDs como medidas, ocultar faltantes ou inferir propriedades populacionais a partir de uma pequena amostra de conveniência.
- Tratamento de ausências e denominadores: Considere 20 fichas com 1 informação de emprego ausente. A frequência de uma categoria pode ser 7/20 sobre todos os candidatos ou 7/19 entre respostas válidas: são medidas diferentes, e ambas exigem rótulo explícito. Excluir linhas silenciosamente altera a população efetivamente analisada.
- Classes e discretização: Um histograma divide o domínio em intervalos e usa a área para representar frequência ou densidade. A escolha do número e largura das classes pode esconder multimodalidade. Teste diferentes larguras, publique os limites dos intervalos e não apresente a discretização como uma propriedade fixa dos dados.
- Protocolo de auditoria: Registre esquema, tipos, intervalo esperado, contagens de nulos, duplicações e impossibilidades semânticas antes da análise. Valide também o significado de cada linha: uma pessoa pode possuir vários registros, e contá-los como indivíduos inflacionará indicadores.