Fundamentos e organização dos dados

Estatística · consulta rápida de fórmulas e sintaxe

LER / INSPECIONAR

Carregar tabela

```
import pandas as pd
df = pd.read_csv("dados.csv")
```

Ajuste o caminho ao dataset.

Primeira auditoria

```
print(df.shape)
print(df.dtypes)
print(df.isna().sum())
```

Tipos, ausências e volume.

Selecionar colunas

```
x = df[["idade", "renda"]]
y = df["classe"]
```

Defina a variável-alvo antes.

LIMPAR / TRANSFORMAR

Remover duplicatas

```
df = df.drop_duplicates()
```

Decida o identificador único.

Converter numérico

```
df["valor"] = pd.to_numeric(
    df["valor"], errors="coerce")
```

Valores inválidos viram NaN.

Agrupar

```
res = df.groupby("grupo",
    dropna=False)["valor"].agg(
    ["count", "mean", "median"])
```

count ignora NaN; size não.

DESCREVER / CUIDADOS

Resumo

```
print(df.describe(include="all"))
```

Observe unidades e assimetria.

Frequências

```
print(df["classe"].value_counts(
    dropna=False, normalize=True))
```

Proporções somam 1.

Exportar resultado

```
res.to_csv("resumo.csv")
```

Não sobrescreva os dados brutos.

Receitas de consulta: adapte dados, colunas, credenciais e versões. Execute somente em ambientes autorizados.