GUIA TÉCNICO EP / MÓDULO 01

Fundamentos e Organizacao de Dados

Referência didática aprofundada elaborada a partir do notebook revisado, com fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 01_fundamentos_e_organizacao_de_dados.ipynb

Objetivos de aprendizagem: classificar variáveis, identificar granularidade e construir frequências e gráficos apropriados

Pré-requisitos: Python e Pandas

Origem: Slides, aulas 01a–01b, páginas 8–56; tabela de candidatos transcrita da página 22. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)

def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)

RNG = np.random.default_rng(42)
```

1. População, unidade e variáveis

População é o conjunto de unidades de interesse; amostra é um subconjunto observado. A unidade de análise determina o significado de uma linha. Variáveis qualitativas são nominais ou ordinais; quantitativas são discretas ou contínuas. Um identificador numérico, como id, não é uma variável quantitativa para calcular média.

```
df = ler_dataset('candidatos_reconstruidos.csv')
display(df.head())
print('Unidade de análise: um candidato; linhas:',len(df),'colunas:',df.shape[1]); assert df['id'].is_un
```

2. Frequências e valores ausentes

A frequência absoluta conta unidades; a relativa divide pelo total adequado. Decida se valores ausentes entram como categoria explícita e declare o denominador. O value_counts(dropna=False) inclui ausentes.

```
freq = df['sexo'].value_counts(dropna=False).rename('n').to_frame()
freq['proporcao'] = freq['n'] / len(df)
freq['percentual'] = 100*freq['proporcao']
display(freq)
assert freq['n'].sum()==len(df)
print(df['empregos_anteriores'].value_counts(dropna=False).sort_index())
```

3. Tabelas de dupla entrada

Uma tabela cruzada mostra combinações de categorias. A normalização por linha responde a uma pergunta diferente da normalização pelo total.

```
tab = pd.crosstab(df['sexo'], df['escolaridade'])
display(tab)
display(pd.crosstab(df['sexo'],df['escolaridade'],normalize='index').round(3))
```

4. Agrupamento em classes

Para uma variável quantitativa contínua, classes têm limites explícitos e a escolha da largura altera o histograma. pd.cut usa por padrão intervalos abertos à esquerda e fechados à direita; ajustamos conscientemente os limites.

```
idades=df['idade']; classes=pd.cut(idades,bins=[17,19,21,23,26],include_lowest=True)
display(classes.value_counts(sort=False))
fig,ax=plt.subplots(figsize=(7,3));ax.hist(idades,bins=[17,19,21,23,26],edgecolor='black');ax.set(xlabel
```

5. Escolha dos gráficos

Barras: categorias. Histograma: distribuição numérica. Pareto: categorias ordenadas por frequência. Um gráfico de setores só é defensável quando as categorias são poucas e compõem um todo.

```
f=df['escolaridade'].value_counts()
fig,ax=plt.subplots(figsize=(7,3));f.plot.bar(ax=ax);ax.set(xlabel='Escolaridade',ylabel='Candidatos',ti
acum=100*f.cumsum()/f.sum();display(pd.DataFrame({'frequencia':f,'percentual_acumulado':acum.round(1)}))
```

Exercício resolvido — Frequência de emprego não informado

Solução comentada:

```
faltantes=df['empregos_anteriores'].isna().sum(); taxa=faltantes/len(df)
print(f'Não declarados: {faltantes} de {len(df)} = {taxa:.1%}');assert faltantes==1
```

Interpretação: Há uma resposta não declarada; excluí-la silenciosamente altera o denominador das proporções.

Exercício resolvido — Frequência dos candidatos por sexo

Solução comentada:

```
homens=(df['sexo']=='M').sum(); mulheres=(df['sexo']=='F').sum()
print(homens,mulheres); assert (homens,mulheres)==(7,13)
```

Interpretação: A tabela original informa sete homens e treze mulheres, entre vinte candidatos; essas frequências não descrevem a população externa de candidatos.

Erros comuns e limites

Evite interpretar IDs como medidas, ocultar faltantes ou inferir propriedades populacionais a partir de uma pequena amostra de conveniência.

Consulta Rápida

df.shape; df.info(); s.value_counts(dropna=False); pd.crosstab(a,b); pd.cut(x,bins=...); ax.hist(...); ax.bar(...).

Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

Aprofundamento v2 — Proveniência, unidade de análise e dados ausentes

Pergunta estatística antes do código: qual é a população-alvo, a unidade de análise, o processo de coleta e a definição operacional de cada variável? Uma contagem de registros não equivale a uma amostra representativa. Os 20 candidatos em candidatos_reconstruidos.csv foram reconstruídos para ensino: não representam uma população contemporânea.

A porcentagem de respostas ausentes precisa trazer seu denominador. Ao analisar apenas casos completos, o tamanho amostral pode variar de variável para variável, influenciando comparações e conclusões. Não se deve imputar automaticamente um valor ausente sem hipótese justificável.

```
base_dados = pd.read_csv(DATASETS / 'candidatos_reconstruidos.csv')
resumo_qualidade = pd.DataFrame({
    'tipo': base_dados.dtypes.astype(str),
    'nao_nulos': base_dados.notna().sum(),
    'ausentes': base_dados.isna().sum(),
    'pct_ausentes': 100 * base_dados.isna().mean()
})
display(resumo_qualidade.round(1))
assert base_dados['id'].is_unique
assert (resumo_qualidade['pct_ausentes'].between(0, 100)).all()
print('Linhas (unidades observacionais):', len(base_dados))
```

Exercício de interpretação com solução

Pergunta: um grupo possui 20 registros e 1 valor ausente na variável de interesse. Qual é a taxa de ausência? Qual denominador usar na frequência relativa das respostas válidas?

Solução: a taxa de ausência é 1/20 = 5%. Para a distribuição entre respostas válidas, o denominador é 19; para a distribuição entre todos os registros, é 20, com ausentes tratados como categoria explícita. Declarar o denominador evita divergências aparentes.

APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

Amostra, população e validade externa

Uma tabela pode ser descrita corretamente e ainda assim não representar a população de interesse. Antes de calcular proporções, defina quem pode integrar a base, em que período e quais unidades ficaram fora. A frequência relativa calculada com uma amostra de conveniência não é, por si só, uma estimativa sem viés da frequência populacional.

Escalas de mensuração e operações válidas

Variáveis nominais permitem comparação de igualdade e contagem; ordinais possuem ordem, mas não distâncias necessariamente equivalentes. Uma escala numérica pode ser codificação de uma categoria e não uma grandeza quantitativa. A classificação correta determina se médias, desvios e histogramas são interpretáveis.

Tratamento de ausências e denominadores

Considere 20 fichas com 1 informação de emprego ausente. A frequência de uma categoria pode ser 7/20 sobre todos os candidatos ou 7/19 entre respostas válidas: são medidas diferentes, e ambas exigem rótulo explícito. Excluir linhas silenciosamente altera a população efetivamente analisada.

Classes e discretização

Um histograma divide o domínio em intervalos e usa a área para representar frequência ou densidade. A escolha do número e largura das classes pode esconder multimodalidade. Teste diferentes larguras, publique os limites dos intervalos e não apresente a discretização como uma propriedade fixa dos dados.

Protocolo de auditoria

Registre esquema, tipos, intervalo esperado, contagens de nulos, duplicações e impossibilidades semânticas antes da análise. Valide também o significado de cada linha: uma pessoa pode possuir vários registros, e contá-los como indivíduos inflacionará indicadores.

PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 1. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.