GUIA TÉCNICO EP / MÓDULO 02

Estatistica Descritiva e Dispersao

Referência didática aprofundada elaborada a partir do notebook revisado, com fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 02_estatistica_descritiva_e_dispersao.ipynb

Objetivos de aprendizagem: comparar medidas de posição e variabilidade e interpretar dados assimétricos

Pré-requisitos: Notebook 01

Origem: Slides, aulas 02–03, páginas 57–92. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)

def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)

RNG = np.random.default_rng(42)
```

1. Medidas de posição

A média usa todos os valores e é sensível a extremos. A mediana identifica o centro ordenado; a moda é o valor mais frequente. A escolha depende da pergunta e do tipo de variável.

```
df=ler_dataset('candidatos_reconstruidos.csv')
x=df['idade']
print('média',x.mean(),'mediana',x.median(),'moda',x.mode().to_list())
print('quantis',x.quantile([.25,.5,.75]).to_dict())
```

2. Variância amostral vs populacional

A variância populacional divide a soma dos desvios quadráticos por N; a variância amostral usual, estimadora não viesada da variância sob amostragem i.i.d., divide por $n-1$. O desvio padrão é sua raiz e tem as unidades originais.

```
m=x.mean();soma=((x-m)**2).sum()
var_pop=soma/len(x);var_amostra=soma/(len(x)-1)
print('Soma dos quadrados',soma,'variância pop',var_pop,'variância amostral',var_amostra)
assert np.isclose(var_amostra,x.var(ddof=1))
assert np.isclose(np.sqrt(var_amostra),x.std(ddof=1))
```

3. IQR, boxplot e assimetria

O intervalo interquartil é $Q3-Q1$. Limites convencionais $Q1-1{,}5\times IQR$ e $Q3+1{,}5\times IQR$ sinalizam potenciais valores atípicos; não são critérios universais para exclusão.

```
q1,q3=x.quantile([.25,.75]);iqr=q3-q1
print('IQR',iqr,'limites',q1-1.5*iqr,q3+1.5*iqr)
fig,axs=plt.subplots(1,2,figsize=(9,3));axs[0].hist(x,bins=range(17,28),edgecolor='black');axs[1].boxplo
```

4. Sensibilidade a extremos — demonstração sintética

Um valor extremo pode deslocar muito a média, enquanto a mediana costuma ser mais estável. Este experimento é artificial e ilustra robustez, não identifica erro nos dados originais.

```
a=np.array([10,11,12,13,14]);b_ext=np.array([10,11,12,13,100])
print(pd.DataFrame({'sem_extremo':[a.mean(),np.median(a)],'com_extremo':[b_ext.mean(),np.median(b_ext)]}
```

5. Dados de desocupação — aplicação com ressalvas

O CSV histórico recuperado não apresenta fonte, ano ou descrição metodológica suficiente. Usaremos apenas sua estrutura para exercícios; não trataremos as taxas como indicadores atuais ou comparáveis entre períodos.

```
taxas=ler_dataset('tx_desocupacao_estados_br.csv')
display(taxas.head());print(taxas['Taxa_desocupacao'].describe().round(2))
print('coeficiente de variação (%)',round(100*taxas['Taxa_desocupacao'].std()/taxas['Taxa_desocupacao'].
```

Exercício resolvido — Conferir os quartis e a contagem

Solução comentada:

```
assert (x.min(),x.max())==(18,25)
print('mínimo, máximo, amplitude:',x.min(),x.max(),x.max()-x.min())
```

Interpretação: A amplitude reflete apenas extremos; para comparar dispersão, use também desvio padrão e IQR.

Exercício resolvido — Variância sob reescala

Solução comentada:

```
y=2*x+5
print(x.var(),y.var());assert np.isclose(y.var(),4*x.var())
```

Interpretação: Multiplicar todos os dados por 2 multiplica o desvio padrão por 2, mas a variância por 4.

Erros comuns e limites

Não confunda variância e desvio padrão nem apresente um boxplot como prova automática de anomalia. ddof=0 e ddof=1 respondem a convenções diferentes.

Consulta Rápida

s.mean() · s.median() · s.mode() · s.quantile([.25,.75]) · s.var(ddof=1) · s.std(ddof=1) · ax.boxplot(s).

Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

Aprofundamento v2 — Estimadores robustos e intervalos interquartis

Média e desvio padrão descrevem posição e dispersão, mas são sensíveis a caudas e valores extremos. Mediana e MAD (median absolute deviation, com constante de normalização quando apropriado) oferecem alternativas robustas. A regra de 1,5×IQR é heurística de exploração, não prova de erro ou fraude.

```
from scipy import stats
amostra_limpa = np.array([10., 11., 12., 13., 14.])
amostra_extremo = np.r_[amostra_limpa[:-1], 100.]
comparacao_robusta = pd.DataFrame({
    'medida': ['media', 'mediana', 'desvio_padrao_amostral', 'MAD_normalizado'],
    'sem_extremo': [amostra_limpa.mean(), np.median(amostra_limpa), amostra_limpa.std(ddof=1), stats.med
    'com_extremo': [amostra_extremo.mean(), np.median(amostra_extremo), amostra_extremo.std(ddof=1), sta
})
display(comparacao_robusta.round(3))
assert abs(np.median(amostra_extremo) - np.median(amostra_limpa)) < abs(amostra_extremo.mean() - amostra
```

Exercício resolvido

Pergunta: por que uma média muito maior que a mediana não deve automaticamente ser removida da análise?

Solução: a diferença pode revelar assimetria legítima. Investigue coleta, domínio, unidade de medida e distribuição antes de qualquer exclusão. Reporte estimativas robustas e não robustas quando houver razões substantivas.

APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

Média, mediana e robustez

A média minimiza a soma dos erros quadráticos e a mediana minimiza a soma dos desvios absolutos. Essa diferença ajuda a explicar por que valores extremos exercem forte influência na média. A escolha da medida depende de assimetria, finalidade e custo do erro; mediana não é sempre melhor.

Variância populacional e amostral

Para uma população completa, a variância divide a soma dos desvios quadráticos por N. Para a variância amostral não viesada sob amostragem i.i.d., divide por n menos 1. A diferença resulta da estimação prévia da média; softwares exigem atenção ao parâmetro ddof.

Dispersão e transformação de unidades

Se Y=aX+b, a média passa a amedia(X)+b, o desvio padrão passa a |a|desvio(X), e a variância passa a a^2*var(X). Assim, padronização, conversão monetária e multiplicação por 100 mudam variâncias de forma distinta das medidas de posição.

Quantis e regras para outliers

O IQR é Q3 menos Q1. Limites de Tukey de 1,5 IQR identificam observações para inspeção, não erros automáticos. Diferentes métodos de interpolação de quantis podem gerar pequenas divergências entre bibliotecas; declare convenções em amostras pequenas.

Coeficiente de variação

O CV compara dispersão relativa quando médias são substantivamente positivas e a escala admite proporções. Próximo de média zero, o indicador explode ou perde significado; para temperaturas em Celsius e outras escalas intervalares, a interpretação de variação relativa é problemática.

PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 2. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.