GUIA TÉCNICO EP / MÓDULO 03

Correlacao e Relacoes Entre Variaveis

Referência didática aprofundada elaborada a partir do notebook revisado, com fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 03_correlacao_e_relacoes_entre_variaveis.ipynb

Objetivos de aprendizagem: distinguir associação e causalidade e usar covariância, Pearson, Spearman e dispersão

Pré-requisitos: Notebook 02

Origem: Slides, aula 04, páginas 93–119; aprofundamento: Spearman. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)

def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)

RNG = np.random.default_rng(42)
```

1. Dispersão e covariância

A covariância mede como duas variáveis variam conjuntamente, mas depende das unidades. A correlação de Pearson padroniza essa relação entre −1 e +1, captando associação linear.

```
x=np.arange(1.,21.)
y=3+2*x+RNG.normal(0,5,size=x.size) # dados sintéticos
amostra=pd.DataFrame({'x':x,'y':y})
print('covariância',amostra.cov().iloc[0,1]);print('Pearson',amostra.corr(method='pearson').iloc[0,1])
fig,ax=plt.subplots(figsize=(6,3));ax.scatter(x,y);ax.set(xlabel='X',ylabel='Y',title='Associação linear
```

2. Associação monotônica — Spearman (aprofundamento)

Spearman aplica Pearson aos postos: detecta tendências monotônicas inclusive quando a associação não é linear. Empates recebem postos médios em implementações comuns.

```
from scipy import stats
curva=x**2
print('Pearson:',stats.pearsonr(x,curva).statistic,'Spearman:',stats.spearmanr(x,curva).statistic)
fig,ax=plt.subplots(figsize=(6,3));ax.scatter(x,curva);ax.set(title='Relação monotônica não linear',xlab
```

3. Correlação espúria e confundimento

Correlação não implica causalidade. Uma terceira variável pode influenciar as duas medidas. Estratificar é útil para investigação, mas não garante identificação causal.

```
# Demonstração sintética: grupos deslocados de modo semelhante
x1=RNG.normal(0,1,100);x2=RNG.normal(5,1,100)
y1=RNG.normal(0,1,100);y2=RNG.normal(5,1,100)
d=pd.DataFrame({'x':np.r_[x1,x2],'y':np.r_[y1,y2],'grupo':['A']*100+['B']*100})
print('correlação agregada',round(d.x.corr(d.y),3));print('por grupo',d.groupby('grupo').apply(lambda g:
```

4. Reta de mínimos quadrados: fundamento apenas

Uma regressão linear simples estima uma reta minimizando a soma dos resíduos quadráticos. Aqui ela serve para compreender inclinação e resíduos; treino, validação e regularização ficam para Aprendizado de Máquina.

```
coef=np.polyfit(x,y,1);prev=np.polyval(coef,x);res=y-prev
print('intercepto e inclinação',coef[1],coef[0],'média dos resíduos',res.mean())
fig,ax=plt.subplots(figsize=(6,3));ax.scatter(x,y);ax.plot(x,prev);ax.set(title='Ajuste linear e observa
```

Exercício resolvido — Verificar o intervalo da correlação

Solução comentada:

```
r=stats.pearsonr(x,y).statistic
assert -1<=r<=1
print('r =',round(r,3),'r² =',round(r**2,3))
```

Interpretação: Em regressão linear simples com intercepto, R^2 coincide com o quadrado de Pearson; fora desse contexto não assuma essa equivalência.

Erros comuns e limites

Correlação não implica causalidade, valores-p não corrigem vieses do desenho e relações não lineares podem apresentar Pearson próximo de zero.

Consulta Rápida

df.cov() · df.corr(method="pearson") · stats.pearsonr(x,y) · stats.spearmanr(x,y) · np.polyfit(x,y,1).

Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

Aprofundamento v2 — Incerteza da correlação e confundimento

A correlação de Pearson mede associação linear e não prova causalidade. Outliers, restrição de amplitude, dependência temporal e subgrupos podem distorcer a estimativa. O intervalo de confiança via transformação de Fisher é aproximado sob amostragem independente e normalidade bivariada, e não resolve vieses de desenho.

Para r e tamanho n > 3, use z = arctanh(r) e erro padrão aproximado 1/sqrt(n-3).

```
from scipy import stats
rng_extra = np.random.default_rng(2026)
x_corr = rng_extra.normal(size=90)
y_corr = 0.5*x_corr + rng_extra.normal(size=90)
r_corr = stats.pearsonr(x_corr, y_corr).statistic
z_corr = np.arctanh(r_corr)
se_z = 1/np.sqrt(len(x_corr)-3)
ic_r = np.tanh([z_corr-1.96*se_z, z_corr+1.96*se_z])
print(f'Correlação de Pearson: {r_corr:.3f}; IC95% aproximado: [{ic_r[0]:.3f}, {ic_r[1]:.3f}]')
assert ic_r[0] < r_corr < ic_r[1]
```

Exercício resolvido

Pergunta: dois indicadores crescem com o tempo e têm $r = 0,92$. Podemos afirmar que um causa o outro?

Solução: não. Tendência temporal comum pode gerar associação espúria; investigue série temporal, mecanismos causais, confundidores e desenho do estudo.

APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

Pearson, Spearman e formas de relação

Pearson padroniza covariância e mede associação linear; Spearman mede associação monotônica pela correlação entre postos. Uma relação em U pode ser forte funcionalmente, mas produzir correlação próxima de zero. Sempre examine o diagrama de dispersão antes do coeficiente.

Correlação espúria e temporalidade

Duas séries podem crescer juntas por tendência temporal compartilhada, sazonalidade ou uma variável comum. Correlação em níveis pode ser enganosa se os processos não forem estacionários. Compare variações, verifique tendências e formule hipóteses causais separadas.

Inclinação e intercepto

Em regressão linear simples, a inclinação estimada é covariancia(X,Y)/variancia(X), se a variância de X não é zero. O intercepto é média(Y) menos inclinação*média(X). Essa reta minimiza a soma dos resíduos quadráticos, mas não garante relações estáveis fora da amplitude observada.

Resíduos e pressupostos

Analise resíduos contra valores ajustados e preditores; procure curvatura, variância não constante e observações influentes. Dependência temporal e confundimento podem comprometer incertezas mesmo quando o R^2 é elevado.

O que significa R^2

Com intercepto e regressão linear simples, R^2 coincide com Pearson^2. A interpretação correta é fração da variação amostral de Y explicada pelo ajuste linear, sob a definição habitual; não é porcentagem da influência causal de X sobre Y.

PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 3. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.