GUIA TÉCNICO

Amostragem e Experimentos

notebook permanece a referência executável.

Propósito — Como utilizar — Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Como utilizar — ROTEIRO DO DOCUMENTO 1. Preparação do ambiente

ROTEIRO DO DOCUMENTO

1. COMO ESTUDAR ESTE MÓDULO
2. Preparação do ambiente
3. IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON
4. 1. Amostragem probabilística
5. 2. Estratos e ponderações
6. 3. Planejamento experimental e randomização
7. 4. Experimento, observacional e causalidade
8. Erros comuns e limites

fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

Propósito — diferenciar amostragens, identificar viés e planejar experimentos

Como utilizar — Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

ROTEIRO DO DOCUMENTO

1. Preparação do ambiente
2. IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON
3. Amostragem probabilística
4. Estratos e ponderações
5. Planejamento experimental e randomização
6. Experimento, observacional e causalidade
7. Erros comuns e limites
8. Consulta Rápida
9. Autoavaliação
10. Aprofundamento v2 — Erro amostral, viés e poder
11. APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE
12. PERGUNTAS DE REVISÃO
13. NOTA DE INTEGRIDADE METODOLÓGICA

COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 04_amostragem_e_experimentos.ipynb

Objetivos de aprendizagem: diferenciar amostragens, identificar viés e planejar experimentos

Pré-requisitos: Fundamentos e probabilidade básica

Origem: Slides, aulas 05–06, páginas 120–145. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

```
# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)
```

```
def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)
```

```
RNG = np.random.default_rng(42)
```

1. Amostragem probabilística

Na amostragem aleatória simples, cada subconjunto de tamanho fixo tem a mesma probabilidade. Sistemática, estratificada e por conglomerados exigem desenhos e ponderações próprios. Uma amostra grande não corrige viés de seleção.

```
pop=np.r_[RNG.normal(10,2,800),RNG.normal(18,2,200)] # população sintética
simple=RNG.choice(pop,100,replace=False)
seletiva=RNG.choice(pop[800:],100,replace=True) # seleção enviesada intencional
print('média população',pop.mean(),'aleatória',simple.mean(),'enviesada',seletiva.mean())
```

2. Estratos e ponderações

A estratificação pode melhorar precisão quando estratos são homogêneos internamente. Se a fração coletada por estrato difere da população, a média simples da amostra pode ter viés.

```
e1=RNG.choice(pop[:800],40,replace=False);e2=RNG.choice(pop[800:],40,replace=False)
media_ponderada=.8*e1.mean()+.2*e2.mean()
print('não ponderada',np.r_[e1,e2].mean(),'ponderada',media_ponderada,'população',pop.mean())
```

3. Planejamento experimental e randomização

Defina unidade experimental, tratamento, desfecho, grupo controle e variável de confusão. Randomização reduz vieses sistemáticos em expectativa, mas não torna amostras pequenas perfeitamente balanceadas.

```
n=200;trat=np.zeros(n,dtype=bool);trat[RNG.choice(n,n//2,replace=False)]=True
base=RNG.normal(50,10,n);resultado=base+4*trat+RNG.normal(0,3,n) # efeito sintético conhecido
print('diferença observada de médias:',resultado[trat].mean()-resultado[~trat].mean())
```

4. Experimento, observacional e causalidade

Uma associação em estudo observacional pode refletir confundimento. Em um ensaio randomizado, o efeito estimado é associado à atribuição aleatória quando respeitados o desenho, a medição e a análise.

```
print('Grupo tratado:',trat.sum(),'controle:',(~trat).sum())
assert trat.sum()==100
```

Exercício resolvido — Reprodutibilidade da amostra

Solução comentada:

```
v=np.arange(100)
a=np.random.default_rng(7).choice(v,10,replace=False)
b2=np.random.default_rng(7).choice(v,10,replace=False)
assert np.array_equal(a,b2)
print('amostra:',a)
```

Interpretação: Definir a semente torna o exemplo reproduzível, não garante representatividade.

Erros comuns e limites

Não use tamanho da amostra como substituto de desenho amostral; distingue-se aleatorização da seleção e aleatorização da atribuição de tratamento.

Consulta Rápida

rng.choice(pop,n,replace=False) · rng.permutation(n) · média estratificada = Σ peso_população × média_estrato.

Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

Aprofundamento v2 — Erro amostral, viés e poder

Representatividade depende do mecanismo de seleção, e não apenas de n. Aumentar uma amostra selecionada por conveniência pode reduzir erro aleatório sem eliminar viés sistemático. Em experimentos, defina desfecho primário, diferença mínima relevante, unidade de randomização e plano de análise antes de observar resultados.

O cálculo a seguir é uma aproximação de planejamento para comparar duas médias independentes, tamanhos iguais, variâncias comuns e teste bilateral normal. Não substitui cálculos específicos para clusters, efeitos heterogêneos ou perdas.

```
from scipy import stats
alpha_planejamento=0.05; poder_desejado=0.80
z_alpha=stats.norm.ppf(1-alpha_planejamento/2)
z_beta=stats.norm.ppf(poder_desejado)
sigma_planejamento=10.0; delta_relevante=5.0
n_por_grupo = int(np.ceil(2*(z_alpha+z_beta)**2*sigma_planejamento**2/delta_relevante**2))
print('Amostra aproximada por grupo:', n_por_grupo)
assert n_por_grupo > 0
```

Exercício resolvido

Pergunta: mantendo variância, alfa e poder, o que ocorre com n se a diferença mínima relevante cair pela metade?

Solução: nesta aproximação, n é proporcional a $1/\text{delta}^2$; portanto, requer aproximadamente quatro vezes mais observações por grupo.

APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

Erro amostral e viés de seleção

Aumentar n reduz variabilidade aleatória, mas não corrige seleção sistemática. Uma amostra online com cem mil respostas pode ser menos representativa do que uma amostra probabilística pequena. Documente quadro amostral, perdas e probabilidades de inclusão.

Estratificação

Na amostragem estratificada, estime a média populacional como soma das médias dos estratos ponderadas pelas proporções populacionais. Ponderar pela quantidade entrevistada pode produzir viés quando a alocação da amostra é desproporcional.

Randomização e unidade experimental

Randomizar pessoas, escolas ou clínicas produz desenhos diferentes. Se o tratamento é atribuído a grupos, unidades dentro de um mesmo grupo podem ter erros correlacionados. O cálculo de incerteza deve refletir a unidade de randomização.

Tamanho de efeito e planejamento

O tamanho da amostra para detectar uma diferença tende a crescer com a variância e com o rigor exigido de poder. Para detectar metade da diferença relevante, em aproximações simples com variância e demais parâmetros fixos, são necessárias cerca de quatro vezes mais observações.

Pré-registro e integridade

Antes de observar o resultado, registre variável principal, critérios de exclusão, modelo e testes previstos. Diferencie análises confirmatórias de investigações exploratórias. Essa distinção reduz seleção oportunista de métricas após a coleta.

PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 4. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.