GUIA TÉCNICO EP / MÓDULO 05

# Fundamentos de Probabilidade

Referência didática aprofundada elaborada a partir do notebook revisado, com fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

## COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 05_fundamentos_de_probabilidade.ipynb

Objetivos de aprendizagem: usar regras de eventos, condicionamento, independência e o teorema de Bayes introdutório

Pré-requisitos: Álgebra básica

Origem: Slides, aula 07, páginas 146–164; aprofundamento: Bayes ilustrativo. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

## Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

# IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)

def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)

RNG = np.random.default_rng(42)
```

## 1. Experimentos e eventos

Um espaço amostral contém os resultados possíveis; eventos são subconjuntos. Para eventos equiprováveis, P(A)=casos favoráveis/casos possíveis. Não aplique essa razão quando resultados não forem equiprováveis.

```
omega=set(range(1,7));A={2,4,6};B={4,5,6}
print('P(A)',len(A)/len(omega),'P(B)',len(B)/len(omega))
print('P(A∩B)',len(A&B)/6,'P(A∪B)',len(A|B)/6)
assert len(A|B)==len(A)+len(B)-len(A&B)
```

## 2. Condicional e independência

P(A|B)=P(A∩B)/P(B) se P(B)>0. Independência exige P(A∩B)=P(A)P(B); eventos disjuntos com probabilidades positivas não são independentes.

```
pA=len(A)/6;pB=len(B)/6;p_inter=len(A&B)/6
print('P(A | B)=',p_inter/pB,'P(A)P(B)=',pA*pB)
```

## 3. Simulação: frequências convergem

Frequência observada aproxima a probabilidade teórica sob repetição independente, mas não precisa convergir monotonicamente nem fornece certeza em uma única amostra.

```
lanc=RNG.integers(1,7,10000)
fracao=np.cumsum(lanc==6)/np.arange(1,len(lanc)+1)
fig,ax=plt.subplots(figsize=(7,3));ax.plot(fracao);ax.axhline(1/6,ls='--');ax.set(xlabel='Lançamentos',y
```

## 4. Teorema de Bayes — primeiro contato (aprofundamento)

Se P(D) é prevalência e P(+|D) sensibilidade, P(D|+) depende também da taxa de falso positivo P(+|não D). Em testes raros, um positivo não garante alta probabilidade posterior.

```
prev=.01;sens=.95;espec=.90
ppv=sens*prev/(sens*prev+(1-espec)*(1-prev))
print('P(condição | positivo)=',round(ppv,4))
```

### Exercício resolvido — Conferência da união de eventos

Solução comentada:

```
pa=3/6;pb=3/6;pab=2/6
resultado=pa+pb-pab
assert np.isclose(resultado,4/6)
print('P(A união B)',resultado)
```

Interpretação: A fórmula subtrai a interseção para não contar resultados comuns duas vezes.

## Erros comuns e limites

Não confunda P(A|B) com P(B|A). Inferência bayesiana completa, com distribuições a priori e posteriores, pertence ao Notebook 09.

## Consulta Rápida

$P(A \cup B) = P(A) + P(B) - P(A \cap B)$; $P(A|B) = P(A \cap B)/P(B)$; $P(A|B) = P(B|A)P(A)/P(B)$ (Bayes).

## Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

## Aprofundamento v2 — Teorema de Bayes e taxa-base

A taxa-base de ocorrência é parte indispensável da interpretação de testes. P(positivo | condição) (sensibilidade) é distinta de P(condição | positivo) (valor preditivo positivo). Mesmo testes com alta sensibilidade podem produzir muitos falsos positivos quando a condição é rara.

```
def valor_preditivo_positivo(prevalencia, sensibilidade, especificidade):
    assert 0 <= prevalencia <= 1 and 0 <= sensibilidade <= 1 and 0 <= especificidade <= 1
    numerador = sensibilidade * prevalencia
    denominador = numerador + (1 - especificidade)*(1-prevalencia)
    return numerador / denominador if denominador > 0 else np.nan
prevalencias = np.array([.01, .05, .20])
resultados_bayes = pd.DataFrame({
    'prevalencia': prevalencias,
    'valor_preditivo_positivo': [valor_preditivo_positivo(p,.95,.90) for p in prevalencias]
})
display(resultados_bayes.round(3))
assert resultados_bayes['valor_preditivo_positivo'].is_monotonic_increasing
```

### Exercício resolvido

Pergunta: a sensibilidade do teste aumentou. É sempre possível concluir que P(condição | positivo) aumentou?

Solução: não sem conhecer prevalência e especificidade. Essas três quantidades entram na fórmula de Bayes e alteram o valor preditivo positivo.

# APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

### Eventos e partições

A probabilidade de A união B é P(A)+P(B)-P(A interseção B). A subtração corrige dupla contagem. Eventos mutuamente exclusivos têm interseção vazia, mas só serão independentes simultaneamente em situações degeneradas de probabilidade zero.

### Condicional e inversão

P(A|B) é a frequência relativa de A no subconjunto em que B ocorreu; não corresponde em geral a P(B|A). A regra do produto escreve P(A interseção B)=P(A|B)P(B), revelando onde hipóteses de independência entram.

### Taxa-base e testes diagnósticos

Quando uma condição é rara, a maioria dos testes positivos pode resultar de falsos positivos mesmo com boa sensibilidade e especificidade. Construa uma tabela de frequências esperadas por 10.000 pessoas antes de interpretar um valor preditivo positivo.

### Lei dos grandes números

A frequência relativa tende a se estabilizar sob repetições adequadas, mas sequências curtas podem oscilar fortemente. A convergência não implica que um resultado futuro compense resultados passados; isso seria falácia do jogador.

### Árvores e contagem

Árvores de probabilidade são úteis para eventos sequenciais com condicionamento; tabelas de contingência ajudam em eventos simultâneos. Use explicitamente os ramos e denominadores para evitar interpretar proporções marginais como condicionais.

# PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

# NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 5. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.