GUIA TÉCNICO EP / MÓDULO 08

Testes de Hipoteses

Referência didática aprofundada elaborada a partir do notebook revisado, com fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 08_testes_de_hipoteses.ipynb

Objetivos de aprendizagem: formular hipóteses, executar testes e relatar evidência, efeito e limites

Pré-requisitos: Notebook 07

Origem: Slides, aula 10, páginas 201–221; aprofundamento: Welch, ANOVA, não paramétricos, multiplicidade e poder. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)

def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)

RNG = np.random.default_rng(42)
```

1. H0, H1, significância e p-valor

O p-valor é calculado sob H0 e não é P(H0|dados). Um teste não mede magnitude de efeito sozinho. Informe hipótese, teste, p-valor, intervalo e tamanho de efeito quando possível.

```
from scipy import stats
A=RNG.normal(50,10,60);B=RNG.normal(54,11,65) # grupos sintéticos
t=stats.ttest_ind(A,B,equal_var=False)
print('Welch t:',t.statistic,'p:',t.pvalue,'diferença B-A:',B.mean()-A.mean())
```

2. Independentes vs pareados

Welch compara médias independentes sem assumir variâncias iguais. Para medidas repetidas nos mesmos indivíduos, a unidade relevante é a diferença pareada.

```
antes=RNG.normal(100,12,30);depois=antes-3+RNG.normal(0,4,30)
tpar=stats.ttest_rel(antes,depois)
print('teste t pareado:',tpar.statistic,tpar.pvalue)
```

3. ANOVA e alternativas (aprofundamento)

ANOVA de uma via avalia igualdade das médias de três ou mais grupos sob pressupostos apropriados; um resultado significativo não informa quais pares diferem. Kruskal–Wallis compara distribuições/ranks e não é um teste universal de medianas.

```
g1=RNG.normal(10,2,35);g2=RNG.normal(11,2,35);g3=RNG.normal(13,2,35)
print('ANOVA:',stats.f_oneway(g1,g2,g3))
print('Kruskal:',stats.kruskal(g1,g2,g3))
```

4. Qui-quadrado em tabelas de contingência

O teste avalia independência entre variáveis categóricas. Verifique frequências esperadas, desenho da amostra e contagens independentes; para 2×2 com poucos dados, considere teste exato de Fisher.

```
obs=np.array([[30,20],[15,35]])
chi,p,gl,expected=stats.chi2_contingency(obs,correction=False)
print('qui²',chi,'p',p,'gl',gl,'esperadas',expected)
assert (expected>0).all()
print('Fisher exato (2x2):',stats.fisher_exact(obs))
```

5. Tamanho de efeito e erros de decisão

Para grupos independentes, d de Cohen divide diferença de médias pelo desvio padrão agrupado (se interpretável). Erro tipo I rejeita H0 verdadeira; tipo II não a rejeita quando falsa. Poder = 1−β.

```
sp=np.sqrt(((len(A)-1)*A.var(ddof=1)+(len(B)-1)*B.var(ddof=1))/(len(A)+len(B)-2))
d=(B.mean()-A.mean())/sp
print('d de Cohen aproximado:',d)
```

6. Múltiplas comparações (aprofundamento)

Se você testa muitos desfechos, a taxa de falsos positivos aumenta. Bonferroni controla o erro familiar; Benjamini–Hochberg controla FDR sob condições específicas.

```
from statsmodels.stats.multitest import multipletests
```

```
ps=np.array([.001,.012,.03,.07,.20])
for metodo in ['bonferroni','fdr_bh']:
 rejeita,ajustados,_,_=multipletests(ps,alpha=.05,method=metodo)
 print(metodo,'rejeições',rejeita,'p ajustados',np.round(ajustados,3))
```

Exercício resolvido — Escolha do teste para dois grupos

Solução comentada:

```
exemplo=pd.DataFrame({'situacao':['duas turmas independentes','antes e depois nos mesmos alunos','duas c
                  'avaliacao':['Welch t (se aplicável)','t pareado (se aplicável)','qui-quadrado/Fisher
display(exemplo)
```

Interpretação: A árvore de decisão começa pela unidade de análise e natureza da variável; pressupostos, tamanho de amostra e objetivo refinam a escolha.

Erros comuns e limites

Falhar em rejeitar H0 não prova equivalência; p pequeno não implica efeito importante. Não selecione testes apenas pela aparência de normalidade em histogramas.

Consulta Rápida

stats.ttest_ind(x,y,equal_var=False) · stats.ttest_rel(x,y) · stats.f_oneway(a,b,c) · stats.chi2_contingency(tab) · stats.fisher_exact(tab) · multipletests(pvals,method="fdr_bh").

Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

Aprofundamento v2 — Intervalos de diferenças, efeito e múltiplos testes

Uma decisão por $p < 0,05$ não informa a magnitude ou relevância prática do efeito. Para grupos independentes com variâncias possivelmente distintas, o teste de Welch e o intervalo de confiança da diferença devem ser interpretados em conjunto. Correções de multiplicidade limitam erros ao testar múltiplas hipóteses relacionadas, mas não corrigem seleção enviesada de resultados.

```
from scipy import stats
from statsmodels.stats.multitest import multipletests
rng_welch=np.random.default_rng(2026)
a_w=rng_welch.normal(10,2,45)
b_w=rng_welch.normal(11,3,50)
dif=b_w.mean()-a_w.mean()
se=np.sqrt(a_w.var(ddof=1)/len(a_w)+b_w.var(ddof=1)/len(b_w))
num=(a_w.var(ddof=1)/len(a_w)+b_w.var(ddof=1)/len(b_w))**2
den=(a_w.var(ddof=1)/len(a_w))**2/(len(a_w)-1)+(b_w.var(ddof=1)/len(b_w))**2/(len(b_w)-1)
gl=num/den
tcrit=stats.t.ppf(.975,gl)
print('Diferença de médias B-A:',round(dif,3),'IC95% Welch:',np.round([dif-tcrit*se,dif+tcrit*se],3))
ps_teste=np.array([.004,.018,.04,.08])
print('FDR-BH:',np.round(multipletests(ps_teste,method='fdr_bh')[1],3))
assert se>0
```

Exercício resolvido

Pergunta: um estudo encontrou $p = 0,003$, mas a diferença observada é de 0,01 unidade, abaixo da diferença mínima considerada relevante. A conclusão é “grande benefício”?

Solução: não. Há evidência contra a hipótese nula sob os pressupostos do teste, mas a importância prática requer tamanho de efeito, IC, custos, contexto e qualidade do desenho.

APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

Lógica dos testes

Formule H0 e H1 antes da análise e escolha estatística de teste coerente com desenho e variável. O p-valor mede compatibilidade dos dados com H0 segundo o procedimento, não probabilidade de H0 ser verdadeira.

Pareado vs independente

Medidas antes/depois na mesma pessoa são pareadas; comparar dois grupos de pessoas distintas é desenho independente. A variância da diferença pareada depende da covariância entre medições; escolher o teste errado pode distorcer a incerteza.

Welch e pressupostos

O teste t de Welch não pressupõe igualdade de variâncias dos grupos. Ainda requer atenção à independência, forma da distribuição e tamanho da amostra. Verifique dados brutos e intervalos para a diferença, não apenas o p-valor.

Múltiplas comparações

Realizar muitos testes aumenta a chance de obter ao menos um falso positivo. Bonferroni controla erro familiar com penalização forte; Benjamini-Hochberg controla taxa esperada de descobertas falsas sob suas condições. Selecione o procedimento conforme a pergunta.

Efeito, poder e interpretação

Diferença estatisticamente detectável pode ser praticamente irrelevante em amostras enormes. Reporte magnitude, unidade, intervalo de confiança, contexto e potência do desenho. Não rejeitar H0 não demonstra equivalência.

PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 8. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.