GUIA TÉCNICO EP / MÓDULO 09

Inferencia Bayesiana

Referência didática aprofundada elaborada a partir do notebook revisado, com fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 09_inferencia_bayesiana.ipynb

Objetivos de aprendizagem: atualizar distribuições a priori em posteriores e produzir probabilidades de decisões

Pré-requisitos: Notebooks 05–07

Origem: Aprofundamento novo, fora do escopo principal dos slides; pressupõe Bayes do Notebook 05. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)

def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)

RNG = np.random.default_rng(42)
```

1. Modelo e atualização

Posterior ∝ verossimilhança × prior. Em inferência bayesiana, a incerteza sobre parâmetros é representada por uma distribuição; uma prior não precisa ser subjetiva, mas deve ser declarada e justificada.

```
from scipy import stats
# Exemplo sintético: 18 sucessos em 30 tentativas, modelo Binomial
n=30;y=18;a0,b0=2,2
a1=a0+y;b1=b0+n-y
print('prior Beta',a0,b0,'posterior Beta',a1,b1)
print('média posterior',a1/(a1+b1))
```

2. Beta–Binomial e intervalo de credibilidade

Com probabilidade θ de sucesso e prior Beta(a,b), observar y sucessos em n tentativas dá posterior Beta(a+y,b+n−y). Um intervalo de credibilidade de 95% contém 95% de massa posterior condicional ao modelo e à prior.

```
eixo=np.linspace(.01,.99,400)
fig,ax=plt.subplots(figsize=(7,3));ax.plot(eixo,stats.beta.pdf(eixo,a0,b0),label='Prior');ax.plot(eixo,s
print('Credibilidade 95%:',stats.beta.ppf([.025,.975],a1,b1))
```

3. Sensibilidade à prior

Para dados escassos, a escolha da prior pode alterar substancialmente as conclusões. Comparar priors plausíveis é parte da análise, não um inconveniente a esconder.

```
priors=[(1,1),(2,2),(10,10)]
for a,beta in priors:
 print((a,beta),'média posterior',round((a+y)/(a+beta+n),3))
```

4. Probabilidade posterior de uma hipótese

Podemos perguntar P(θ>0,5 | dados), mas o resultado depende das hipóteses probabilísticas e dos dados observados. Isso difere diretamente de p-valor frequentista.

```
prob=stats.beta.sf(.5,a1,b1)
print('P(θ > 0,5 | dados, modelo e prior)=',prob)
```

5. Comparação de taxas — simulação posterior

Simulações de duas posteriores permitem estimar a probabilidade de uma taxa superar a outra. O exemplo é sintético e assume independência condicional e modelos Beta–Binomial apropriados.

```
pA=RNG.beta(21,21,50000);pB=RNG.beta(26,16,50000)
print('P(taxa B > taxa A | modelos e dados)=',np.mean(pB>pA))
print('diferença posterior média',np.mean(pB-pA))
```

Exercício resolvido — Posterior sob prior uniforme

Solução comentada:

```
a,beta=1,1;sucessos,tentativas=7,10
post=(a+sucessos,beta+tentativas-sucessos)
assert post==(8,4)
print('Posterior:',post,'esperança:',post[0]/sum(post))
```

Interpretação: Uma prior uniforme Beta(1,1) seguida de sete sucessos em dez tentativas dá Beta(8,4).

Erros comuns e limites

Não apresente resultados posteriores sem explicitar priors, verossimilhança e hipóteses. Técnicas computacionais gerais (MCMC) exigem verificação de convergência e ficam como trilha futura.

Consulta Rápida

stats.beta.pdf(theta,a,b) · stats.beta.ppf([.025,.975],a,b) · stats.beta.sf(limite,a,b) · posterior Beta(a+y,b+n−y).

Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

Aprofundamento v2 — Sensibilidade da posterior à prior

A interpretação bayesiana é condicional ao modelo, à prior e aos dados. Para a conjugação Beta–Binomial, prior=Beta(a,b) e y sucessos em n tentativas resultam em posterior=Beta(a+y, b+n-y). Em amostras pequenas, diferentes priors podem produzir conclusões relevantes distintas.

```
from scipy import stats
sucessos_novos=3;n_novo=5
priors_novos={'uniforme':(1,1),'centrada_05':(10,10),'otimista':(8,2)}
linhas=[]
for nome,(a,beta) in priors_novos.items():
    ap=a+sucessos_novos;bp=beta+n_novo-sucessos_novos
    linhas.append({'prior':nome,'media_posterior':ap/(ap+bp),
                   'p_theta_maior_05':stats.beta.sf(.5,ap,bp)})
quadro_priors=pd.DataFrame(linhas)
display(quadro_priors.round(3))
assert quadro_priors['media_posterior'].between(0,1).all()
```

Exercício resolvido

Pergunta: por que testar mais de uma prior quando há apenas cinco observações?

Solução: porque pouca informação nos dados pode deixar a posterior sensível às crenças anteriores. A análise de sensibilidade torna explícito quanto as conclusões dependem dessas escolhas.

APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

Prior, likelihood e posterior

A distribuição a priori representa informação ou pressupostos antes da amostra; a verossimilhança representa o modelo dos dados; a posterior combina as duas via normalização. Um número posterior é condicional tanto aos dados quanto às hipóteses do modelo.

Conjugação Beta-binomial

Se theta tem prior Beta(a,b) e observamos s sucessos em n tentativas Bernoulli independentes, a posterior é Beta(a+s, b+n-s). Essa atualização transparente permite inspecionar diretamente influência da prior.

Intervalos de credibilidade

Um intervalo de credibilidade de 95% contém 95% da massa posterior do parâmetro, dadas prior e verossimilhança. Essa frase não deve ser confundida com interpretação frequentista de cobertura repetida.

Sensibilidade da prior

Com poucos dados, priors diferentes podem levar a conclusões bastante distintas. Compare uma prior fraca com alternativas plausíveis, reporte resultados lado a lado e explique quais conclusões dependem fortemente da prior.

Probabilidade de superioridade

Em uma comparação de duas proporções, sorteie theta_A e theta_B das respectivas posteriores e calcule a fração de sorteios com theta_A>theta_B. Esse valor não identifica causalidade sem desenho e hipóteses apropriados.

PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 9. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.