GUIA TÉCNICO EP / MÓDULO 10

Modelos Estatisticos Avancados

Referência didática aprofundada elaborada a partir do notebook revisado, com fundamentos, decisões analíticas, código reproduzível, exercícios e interpretação. O notebook permanece a referência executável.

COMO ESTUDAR ESTE MÓDULO

Leia os conceitos antes de executar os exemplos; compare as premissas com os resultados numéricos e resolva os exercícios sem consultar imediatamente a solução. Avalie sempre a unidade de análise, as limitações dos dados e as condições de validade do procedimento.

Notebook associado: 10_modelos_estatisticos_avancados.ipynb

Objetivos de aprendizagem: interpretar GLMs para respostas de contagem e binárias e diagnosticar adequação

Pré-requisitos: Notebooks 03, 06–08

Origem: Aprofundamento novo, além dos slides; regressão preditiva aprofundada permanece em Aprendizado de Máquina. Conteúdos adicionais estão identificados como Aprofundamento.

Convenção: datasets/ reúne dados de entrada; outputs/ reúne resultados. Dados inventados para demonstrações são sempre identificados como sintéticos.

Preparação do ambiente

Execute a célula abaixo. Os notebooks são independentes e não dependem de variáveis definidas em outros arquivos.

IMPLEMENTAÇÕES E VERIFICAÇÕES EM PYTHON

```
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Execute o JupyterLab com o diretório desta disciplina como raiz.
BASE = Path.cwd()
DATASETS = BASE / "datasets"
OUTPUTS = BASE / "outputs"
DATASETS.mkdir(parents=True, exist_ok=True)
OUTPUTS.mkdir(parents=True, exist_ok=True)

def ler_dataset(nome):
    caminho = DATASETS / nome
    if not caminho.is_file():
        raise FileNotFoundError(f"Dataset não encontrado: {caminho}. Abra o JupyterLab na raiz da discip
    return pd.read_csv(caminho)

RNG = np.random.default_rng(42)
```

1. Estrutura de um GLM

GLMs relacionam média da resposta a um preditor linear por uma função de ligação e assumem uma família probabilística. Regressões logística e de Poisson são GLMs; um modelo bem ajustado não demonstra causalidade.

```
import statsmodels.api as sm
x=RNG.uniform(0,5,250)
dados=pd.DataFrame({'x':x})
print('Exemplos de ligações: log para Poisson; logit para Binomial')
```

2. Regressão de Poisson para contagens

Se Y é contagem, $\log(E[Y|X]) = \beta 0+\beta 1\ X$. Então $\exp(\beta 1)$ é uma razão multiplicativa de contagens médias por unidade de X, mantendo outros termos constantes. Taxas por exposição usam offset log(exposição).

```
mu=np.exp(.3+.25*x);contagens=RNG.poisson(mu) # dados sintéticos
X=sm.add_constant(dados[['x']]);m_poi=sm.GLM(contagens,X,family=sm.families.Poisson()).fit()
print(m_poi.params)
print('razão de taxas por unidade X:',np.exp(m_poi.params['x']))
print('AIC:',m_poi.aic)
```

3. Diagnóstico de sobredispersão

Na Poisson, Var(Y|X)=E[Y|X]. Se a variância condicional exceder substancialmente a média, uma hipótese do modelo pode estar inadequada. O diagnóstico depende do desenho e de como a heterogeneidade foi modelada.

```
razao=m_poi.pearson_chi2/m_poi.df_resid
print('Qui² de Pearson / gl residuais:',razao)
print('Deviance / gl residuais:',m_poi.deviance/m_poi.df_resid)
```

4. Binomial negativa como alternativa

O GLM binomial negativo permite variância maior que a média. Nesta implementação o parâmetro alpha da família é fixado; estimá-lo requer outro procedimento. Comparações de ajuste exigem modelos adequados e critérios consistentes.

```
nb=sm.GLM(contagens,X,family=sm.families.NegativeBinomial(alpha=1.0)).fit()
print('Coeficientes NB (alpha fixo):',nb.params.to_dict())
print('AIC NB:',nb.aic)
```

5. Modelo binomial: interpretação estatística

No modelo logit, log(p/(1−p))=β0+β1X. exp(β1) é razão de odds, não razão de probabilidades. Treino de classificadores, validação cruzada e métricas preditivas aprofundadas ficam em Machine Learning.

```
prob=1/(1+np.exp(-(-1.5+.6*x)))
y=RNG.binomial(1,prob) # sintético
model_logit=sm.GLM(y,X,family=sm.families.Binomial()).fit()
print('coeficiente X:',model_logit.params['x'],'odds ratio:',np.exp(model_logit.params['x']))
print('intervalo 95% de odds ratio:',np.exp(model_logit.conf_int().loc['x']).to_numpy())
```

6. Resíduos e comparação de modelos

AIC compara compromisso entre ajuste e complexidade para modelos construídos sobre os mesmos dados. Diagnósticos requerem atenção a influência, resíduos, especificação, dependência e possíveis variáveis omitidas.

```
fig,ax=plt.subplots(figsize=(7,3));ax.scatter(m_poi.fittedvalues,m_poi.resid_pearson,alpha=.5);ax.axhlin
```

Exercício resolvido — Transformar coeficiente em razão

Solução comentada:

```
beta=.2;rr=np.exp(beta)
print('razão multiplicativa por +1 em X:',rr)
assert rr>1
```

Interpretação: Um coeficiente de 0,2 em ligação log corresponde a aproximadamente 22% de aumento na média da resposta, condicional ao modelo, não a 0,2 eventos adicionais.

Erros comuns e limites

Não confunda odds com probabilidade, p-valor de coeficiente com capacidade preditiva nem critério AIC com prova causal. Ajuste e seleção devem respeitar a distribuição da resposta e o desenho dos dados.

Consulta Rápida

sm.GLM(y,X,family=sm.families.Poisson()).fit() · sm.GLM(y,X,family=sm.families.Binomial()).fit() · np.exp(coef) · resultado.conf_int() · resultado.aic.

Autoavaliação

Antes de seguir, explique com suas palavras: qual é a pergunta estatística, qual método responde a ela, quais pressupostos devem ser verificados e o que não podemos concluir?

Aprofundamento v2 — Diagnóstico de GLMs e validação fora da amostra

Para contagens, a função de ligação log implica $E[Y|X]=\exp(X\beta)$; $\exp(\beta)$ é uma razão multiplicativa de taxas/médias, não uma diferença absoluta. Para respostas binárias, $\exp(\beta)$ em ligação logit representa odds ratio, não risco relativo.

Um GLM binomial pode exibir separação perfeita; modelos de contagem podem ter sobredispersão e excesso de zeros. AIC é comparação relativa entre modelos ajustados à mesma resposta e amostra, e não substitui diagnóstico nem validação.

```
import statsmodels.api as sm
rng_glm=np.random.default_rng(2026)
x_glm=rng_glm.normal(size=320)
mu_glm=np.exp(.2+.35*x_glm)
y_glm=rng_glm.poisson(mu_glm)
indices=rng_glm.permutation(len(y_glm))
train=indices[:240];test=indices[240:]
X_glm=sm.add_constant(x_glm)
modelo_glm=sm.GLM(y_glm[train],X_glm[train],family=sm.families.Poisson()).fit()
prev_glm=modelo_glm.predict(X_glm[test])
mae_glm=np.mean(np.abs(y_glm[test]-prev_glm))
print('MAE em amostra de teste simulada:',round(mae_glm,3))
print('Razão multiplicativa estimada para +1 em x:',round(np.exp(modelo_glm.params[1]),3))
assert (prev_glm>0).all() and mae_glm>=0
```

Exercício resolvido

Pergunta: um coeficiente logit é $0{,}7$. Podemos afirmar que o risco dobrou?

Solução: não. $\exp(0{,}7)\approx 2{,}01$ corresponde às odds multiplicadas por aproximadamente 2, e não necessariamente à probabilidade ou ao risco relativo duplicado.

APROFUNDAMENTO CONCEITUAL E CRITÉRIOS DE VALIDADE

GLM e ligação

Um modelo linear generalizado combina família de distribuição, preditor linear e função de ligação. A ligação transforma a média condicional para a escala linear; não confunda a escala do coeficiente com unidades diretas da resposta.

Poisson com exposição

Em taxas de eventos, um offset log(exposição) permite modelar contagens com tempos ou populações de risco diferentes. Sem offset, mais eventos podem refletir apenas mais oportunidade de ocorrência, não maior taxa.

Sobredispersão

Se a variância condicional de contagens é muito maior que a média, a Poisson pode subestimar incertezas. Inspecione resíduos, dispersão, estrutura de grupos e zeros, considerando binomial negativa ou alternativas adequadas.

Logit, odds e risco

No logit, exp(coeficiente) representa razão de odds associada a uma unidade do preditor, mantidas condições do modelo. Odds não é probabilidade, e uma razão de odds não equivale automaticamente a razão de riscos.

Validação e diagnóstico

AIC só compara modelos em base e verossimilhanças comparáveis e não garante desempenho preditivo. Use separação treino/teste quando há objetivo de previsão, examine resíduos, calibração e possíveis mudanças de distribuição.

PERGUNTAS DE REVISÃO

1. Quais são as unidades de análise e os pressupostos essenciais deste método? 2. Que resultado mudaria se os dados fossem coletados por outro mecanismo? 3. Como distinguir significância matemática, evidência estatística e relevância substantiva? 4. Qual diagnóstico pode falsificar a interpretação pretendida?

NOTA DE INTEGRIDADE METODOLÓGICA

Os exemplos reproduzem o material executável já revisado e não autorizam generalização estatística fora de suas hipóteses. Confirme premissas, independência, mecanismo amostral, unidades e cobertura dos dados antes de transformar uma saída computacional em conclusão.

Fonte didática: notebook revisado do módulo 10. A compilação histórica de aulas foi usada somente como referência temática; seus slides não são reproduzidos neste guia.