GUIA TÉCNICO EP / DISCIPLINA 04

MongoDB: agregações e índices

Pipelines, agregações, índices e análise de consultas

MAPA DE ESTUDO

01 Pipelines de agregação

02 Filtragem, projeção e agrupamento

03 Estratégias de indexação

04 Avaliação de desempenho e seletividade

05 Execução real opcional

Material de referência complementar aos notebooks. Exemplos locais com dados sintéticos; laboratórios externos somente sob configuração explícita.

08 | MongoDB: agregações e índices

GUIA TÉCNICO APROFUNDADO • ANÁLISE, CÓDIGO E INTERPRETAÇÃO

Objetivo e escopo

Estudo independente baseado no notebook aprovado. Os exemplos locais usam SQLite e dados sintéticos; PostgreSQL, MongoDB e Cassandra requerem serviços de laboratório para verificação real.

Conceito central: Pipelines de agregação

$match reduz registros conforme o filtro; $unwind expande arrays; $group combina ocorrências; $sort ordena. Em dados grandes, a posição dos estágios e a seletividade de índices influenciam desempenho. Examine explain na instância real.

Aplicação, ressalvas e limites

Uma contagem feita localmente com Counter é um controle independente dos dados, não uma execução do pipeline em MongoDB.

Aggregation pipeline

Etapas como $match, $unwind, $group e $sort transformam documentos em resultados agregados. A ordem pode afetar uso de índices e volume processado.

Exemplo do notebook — execução local

```
import json,os
usuarios=json.loads((DATA/'usuarios_sinteticos.json').read_text(encoding='ut
    f8'))
pipeline=[{'$unwind':'$interesses'},{'$group':{'_id':'$interesses','quantida
    de':{'$sum':1}}},{'$sort':{'quantidade':-1,'_id':1}}]
print(json.dumps(pipeline,ensure_ascii=False,indent=2))
```

Exemplo do notebook — laboratório opcional, exige serviço isolado

```
# Pré-requisito opcional: serviço MongoDB local e RUN_LIVE_DB=1.
# Nenhuma conexão será feita ao executar Run All no modo padrão.
import os
if os.getenv('RUN_LIVE_DB') == '1':
    from pymongo import MongoClient
    with MongoClient('mongodb://127.0.0.1:27017',serverSelectionTimeoutMS=50
    00) as cliente:
        print('Servidor alcançável:',cliente.admin.command('ping'))
else:
    print('Diagnóstico remoto ignorado (modo seguro, sem MongoDB).')
print('Usuários definidos:', 'usuarios' in globals())
print('Pipeline definido:', 'pipeline' in globals())
```

Exemplo do notebook — laboratório opcional, exige serviço isolado

```
import os
print(os.getenv("RUN_LIVE_DB"))
```

Exemplo do notebook — laboratório opcional, exige serviço isolado

```
# A execução local não ativa conexões automaticamente.
# Para laboratórios opcionais, configure RUN_LIVE_DB=1 antes de iniciar o ke
    rnel,
# depois de verificar que a instância é EXCLUSIVAMENTE de estudos.
import os
print('Laboratório externo:', 'habilitado' if os.getenv('RUN_LIVE_DB') == '1
    ' else 'desabilitado (padrão seguro)')
```

Exemplo do notebook — laboratório opcional, exige serviço isolado

```
# IMPORTANTE: só execute em instância de laboratório isolada.
# Cria coleção NOVA e exclusiva; nunca exclui coleções preexistentes.
import os
if os.getenv('RUN_LIVE_DB') == '1':
    from uuid import uuid4
    from pymongo import MongoClient
    with MongoClient('mongodb://127.0.0.1:27017',serverSelectionTimeoutMS=30
    00) as cli:
        cli.admin.command('ping')
        nome = 'aula08_' + uuid4().hex[:12]
        col = cli['puc04_laboratorio'][nome]
        col.insert_many(usuarios)
        col.create_index([('cidade',1),('ativo',1)])
        print('Coleção criada nesta sessão:',nome)
        print('Agregação real:', list(col.aggregate(pipeline)))

        print('Índices:', list(col.index_information()))
else:
    print('Laboratório MongoDB não executado (RUN_LIVE_DB diferente de 1).')
```

Prática real - pipeline e índice

Ative MongoDB local e RUN_LIVE_DB=1. Para evitar depender de uma execução prévia, este notebook prepara sua própria coleção de treinamento.

Exercício resolvido - interesse mais comum

Compare o pipeline com a contagem local, que atua apenas como verificação de expectativa, e não como emulação da engine.

Exemplo do notebook — execução local

```
from collections import Counter
cont=Counter(t for user in usuarios for t in user['interesses']);print(cont.
    most_common());assert cont['dados']==3
```

Interpretação de desempenho

Índices aceleram algumas leituras, mas custam espaço e escrita; explain() deve ser analisado com cardinalidade e dados reais, não com apenas seis documentos.

--- ### Aprofundamento v2 - Pipeline e índices adequados

Em MongoDB, o desempenho de $match, $group e $unwind depende da ordem e da seletividade. Avalie com explain() quando o servidor estiver disponível e não interprete um índice criado como garantia de aceleração. Diferencie a saída de agregação real da verificação em Python.

Interpretação: compare o resultado com a teoria anterior; este exemplo local não substitui um laboratório de serviço externo.

Exemplo do notebook — execução local

```
from collections import Counter
contagem=Counter(i for u in usuarios for i in u.get('interesses',[]))
assert sum(contagem.values())==sum(len(u.get('interesses',[])) for u in usua
    rios)
print('Agregação de referência:',contagem.most_common(5))
```

Exercício de revisão

Exercício resolvido - revisão: identifique a principal hipótese do exemplo acima, explique por que ela importa e cite uma condição na qual a técnica falharia. Resposta orientadora: registre a pré-condição (tipo de dado, chave, restrição, volume ou topologia), teste-a explicitamente e explique os limites dos resultados observados.

Aprofundamento: decisões e estudo de caso

Pipelines: cardinalidade intermediária

$unwind pode transformar um documento com quatro interesses em quatro linhas lógicas do pipeline; por isso a contagem após expandir o array mede interesses, não necessariamente usuários únicos. Para contar pessoas por interesse, a deduplicação pode ser necessária dependendo do esquema. O estágio $group muda a granularidade, e $sort apresenta a ordem da métrica resultante.

Filtros antes ou depois

$match posicionado cedo costuma reduzir o volume processado, mas nem sempre pode ser movido sem mudar o significado. Filtrar usuários ativos antes de $unwind é diferente de filtrar os grupos já produzidos. A semântica da pergunta deve orientar a ordem dos estágios, antes de qualquer tentativa de otimização.

Índice e explain

Índices compostos precisam corresponder aos filtros e à ordenação de consultas reais. A presença de um índice não é prova de uso; examine explain e estatísticas de execução na instância MongoDB. Custos de atualização e memória também devem entrar na comparação. Uma lista local de Counter só fornece valores esperados, não métricas do motor.

Exercício de pipeline

Construa uma lista ordenada dos interesses mais frequentes dos usuários sintéticos, primeiro com Counter e depois com o pipeline real opcional. Compare os resultados e descreva uma situação em que o uso de $unwind altera o denominador de uma taxa de usuários.

Checklist de interpretação

- Defina a pergunta, unidade de análise e pré-condições da consulta.
- Registre chaves, cardinalidade, restrições e tratamento de valores ausentes.
- Execute os exemplos locais antes de habilitar serviços reais.
- Separe evidência observada de hipóteses e propriedades não testadas.

Leituras e arquivos de apoio

Consulte o notebook correspondente, os scripts em sql/, os datasets sintéticos e a documentação oficial dos SGBDs. Os resultados locais não substituem testes de integração com serviços externos.