DBSCAN e avaliação de clusters

DBSCAN

Ajustar densidade

```
from sklearn.cluster import DBSCAN
from sklearn.preprocessing import StandardScaler
Z=StandardScaler().fit_transform(X)
lab=(DBSCAN(eps=.5,min_samples=5)
 .fit_predict(Z))
```

eps depende da escala e densidade.

Ruído

```
import numpy as np
print((lab==-1).sum())
```

-1 significa pontos de ruído.

AVALIAR

Contar clusters

```
k=len(set(lab)-{-1})
print("clusters:",k)
```

DBSCAN não exige k previamente.

Silhouette sem ruído

```
mask=lab!=-1
if len(set(lab[mask]))>1:
 print(silhouette_score(
 Z[mask],lab[mask]))
```

Remova ruído conscientemente.

Vizinhos mais próximos

```
from sklearn.neighbors import NearestNeighbors
d=(NearestNeighbors(n_neighbors=5)
 .fit(Z).kneighbors(Z)[0][:,-1])
```

Gráfico de d pode apoiar eps.

LIMITES

Variar parâmetros

```
for eps in [.3,.5,.8]:
 labs=DBSCAN(eps=eps).fit_predict(Z)
 print(eps,len(set(labs)-{-1}))
```

Sensível aos parâmetros.

Diagnóstico

```
print(np.unique(lab,return_counts=True))
```

Alta dimensionalidade dificulta distância.

Nota

```
print(Z.shape)
```

Cluster não é classe verdadeira.