Fundamentos de Machine Learning

Dividir Corretamente · Separar X/Y

DIVIDIR CORRETAMENTE

Separar X/y

```
X = df.drop(columns="alvo")
y = df["alvo"]
```

Nunca incluir target nos atributos.

Treino/teste

```
from sklearn.model_selection import train_test_split
Xtr,Xte,ytr,yte = train_test_split(
 X,y,test_size=.2,random_state=42,
 stratify=y)
```

stratify em classificação.

TREINAR UM BASELINE

Pipeline simples

```
from sklearn.pipeline import make_pipeline
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression
modelo = make_pipeline(
 SimpleImputer(),LogisticRegression(
 max_iter=1000))
```

Imputação ajustada só no treino.

Fit / predict

```
modelo.fit(Xtr,ytr)
yhat = modelo.predict(Xte)
```

Teste somente após decisão do modelo.

AVALIAR / REPRODUZIR

Classificação

```
from sklearn.metrics import classification_report
print(classification_report(yte,yhat))
```

Compare classe minoritária.

Validação cruzada

```
from sklearn.model_selection import cross_val_score
scores = cross_val_score(
 modelo,Xtr,ytr,cv=5)
```

Não use teste para ajustar.

Baseline dummy

```
from sklearn.dummy import DummyClassifier
base = DummyClassifier(strategy="prior")
```

O modelo deve superar o trivial.