Metodologia de experimentos ML

HOLDOUT

Dividir antes do fit

```
from sklearn.model_selection import train_test_split
Xtr,Xte,ytr,yte=train_test_split(
 X,y,test_size=.2,random_state=42)
```

Teste deve permanecer intocado.

Estratificar

```
Xtr,Xte,ytr,yte=train_test_split(
 X,y,stratify=y,random_state=42)
```

Para categorias de classificação.

CV E PIPELINE

K-fold estratificado

```
from sklearn.model_selection import StratifiedKFold
cv = StratifiedKFold(
 n_splits=5,shuffle=True,random_state=42)
```

Para classificação.

Comparar modelo

```
from sklearn.model_selection import cross_validate
r = cross_validate(pipe,Xtr,ytr,cv=cv,
 scoring=["accuracy","f1_macro"])
```

Reporte dispersão entre folds.

AUDITAR

Baseline

```
from sklearn.dummy import DummyClassifier
b = DummyClassifier(strategy="most_frequent")
print(cross_val_score(b,Xtr,ytr,cv=cv))
```

Baseline antes de tunar.

Grupos

```
from sklearn.model_selection import GroupKFold
cv = GroupKFold(n_splits=5)
```

Use groups em amostras correlatas.

Tempo

```
from sklearn.model_selection import TimeSeriesSplit
cv = TimeSeriesSplit(n_splits=5)
```

Não embaralhe eventos temporais.

Receitas de consulta: adapte dados, colunas, credenciais e versões. Execute somente em ambientes autorizados.