DATA SCIENCE / QUICK REFERENCE

Preparação de Dados, Engenharia de Atributos e Pipelines

CONCEITOS

Objetivo 1

Pré-processamento sem vazamento

Objetivo 2

Imputação, codificação, escalonamento e seleção devem ser ajustados dentro da validação

Objetivo 3

Pipeline e ColumnTransformer encapsulam esse comportamento e reduzem inconsistência entre treino e inferência

PRÁTICA PYTHON

Padrão 1

```
from sklearn.model_selection import
train_test_split
```

Padrão 2

```
from sklearn.pipeline import make_pipeline
```

Padrão 3

```
p.fit(X_treino)
```

VALIDAÇÃO E CUIDADOS

Nota 1

Fazer split ANTES de fit/fit_transform de qualquer transformação aprendida.

Nota 2

Pipeline dentro de cross_val_score reestima transformadores a cada fold.

Nota 3

Usar ColumnTransformer para dados heterogêneos.

Nota 4

Validar valores desconhecidos e colunas ausentes.

Nota 5

Fazer fit_transform em toda a tabela antes de cross-validation permite vazamento de estatísticas globais. Campos identificadores não são automaticamente bons atributos preditivos.

Consulta rápida. Compare com o guia técnico e interprete resultados no contexto dos dados.