Preparação de dados e pipelines

Numéricos · Pipeline Numérico

NUMÉRICOS

Pipeline numérico

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
num = Pipeline([("impute",
 SimpleImputer(strategy="median")),
 ("scale",StandardScaler())])
```

Fit só nos folds de treino.

CATEGÓRICOS

One-hot

```
from sklearn.preprocessing import OneHotEncoder
cat = OneHotEncoder(
 handle_unknown="ignore")
```

Novas categorias não quebram predição.

ColumnTransformer

```
from sklearn.compose import ColumnTransformer
pre = ColumnTransformer([
 ("num",num,num_cols),
 ("cat",cat,cat_cols)])
```

Evite vazamento por pré-processar fora.

PIPELINE FINAL

Modelo inteiro

```
from sklearn.linear_model import LogisticRegression
pipe = Pipeline([("prep",pre),
 ("clf",LogisticRegression(
 max_iter=1000))])
pipe.fit(Xtr,ytr)
```

Encadeie fit/transform corretamente.

Previsão

```
yhat = pipe.predict(Xte)
```

Testes só após ajuste.

Salvar

```
import joblib
joblib.dump(pipe,"modelo.joblib")
```

Somente carregue arquivos confiáveis.