DATA SCIENCE / QUICK REFERENCE

# Validação Cruzada, Seleção e Otimização

## CONCEITOS

### Objetivo 1

Cross-validation e busca

### Objetivo 2

Cross-validation aproxima o desempenho usando múltiplas partições; o método de particionamento deve respeitar estratificação, tempo e grupos

### Objetivo 3

GridSearchCV avalia combinações no treino, mas sua melhor pontuação tende a ser otimista após muitas tentativas

## PRÁTICA PYTHON

### Padrão 1

```
from sklearn.pipeline import make_pipeline
```

### Padrão 2

```
pipe=make_pipeline(StandardScaler(),KNeighborsClassifier())
```

### Padrão 3

```
grid.fit(a,c)
```

### Padrão 4

```
r.fit(a,c)
```

## VALIDAÇÃO E CUIDADOS

### Nota 1

GridSearchCV: grade fixa; RandomizedSearchCV: amostragem de combinações.

### Nota 2

scoring deve representar a decisão de negócio.

### Nota 3

Teste é avaliação final, não um instrumento de tuning.

### Nota 4

Registrar random_state, versões e tempo de execução.

### Nota 5

Nunca relatar o melhor score interno da busca como desempenho final em dados inéditos. Muitas comparações sobre o mesmo teste acabam transformando-o implicitamente em validação.

Consulta rápida. Compare com o guia técnico e interprete resultados no contexto dos dados.