EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



01 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Fundamentos de Machine Learning

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

Classificação prevê categorias; regressão prevê uma quantidade; agrupamento procura estrutura sem rótulos. Antes de escolher uma técnica, defina a unidade de observação, a origem do rótulo, o custo de cada erro e o que um resultado satisfatório permitiria decidir. Uma baseline simples estabelece o desempenho mínimo que um método mais caro deve superar.

Ponto de atenção

É comum selecionar um algoritmo sofisticado antes de definir a métrica. Em classes desbalanceadas, um classificador constante pode apresentar grande acurácia e ainda ser inútil para detectar a classe rara.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Distinguir tarefas de classificação, regressão e agrupamento; reconhecer aprendizado supervisionado/não supervisionado, *batch*/*online*, baseado em instâncias/modelos; formular objetivo e baseline.

Panorama: um modelo aprende parâmetros ou estrutura a partir de exemplos; o objetivo preditivo é generalizar para observações não vistas. Não confundir ajuste no treino com qualidade fora da amostra. Métodos baseados em instâncias (ex.: KNN) usam exemplos para decidir; baseados em modelos (ex.: regressão logística) aprendem parâmetros. Em *batch*, reentrena-se em lotes; em *online*, atualiza-se incrementalmente quando o estimador dá suporte a isso.

Outros paradigmas: regras de associação procuram coocorrências, não se confundem com classificação. Aprendizado por reforço é apenas contextualizado: não faz parte do escopo prático desta disciplina.

Interpretação prática

Classificação prevê categorias; regressão prevê uma quantidade; agrupamento procura estrutura sem rótulos. Antes de escolher uma técnica, defina a unidade de observação, a origem do rótulo, o custo de cada erro e o que um resultado satisfatório permitiria decidir. Uma baseline simples estabelece o desempenho mínimo que um método mais caro deve superar.

2. Fundamentos matemáticos

Notação: dados Xin{R}^{ntimes p}, rótulos yinmathcal{Y}^n e preditor hat y=f_theta(X). O risco de generalização é R(f)={E}_{(X,Y)sim P}[L(Y,f(X))], desconhecido; a avaliação em dados separados aproxima esse risco sob hipóteses sobre a amostragem.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_iris, load_diabetes
from sklearn.model_selection import train_test_split
from sklearn.dummy import DummyClassifier, DummyRegressor
from sklearn.metrics import accuracy_score, mean_absolute_error
Xc, yc = load_iris(return_X_y=True)
Xtr, Xte, ytr, yte = train_test_split(Xc, yc, test_size=.25, random_state=42, stratify=yc)
clf_base = DummyClassifier(strategy='most_frequent').fit(Xtr,ytr)
print('Baseline classificação (accuracy):',round(accuracy_score(yte,clf_base.predict(Xte)),3))
Xr,yr = load_diabetes(return_X_y=True)
Xtr_r,Xte_r,ytr_r,yte_r=train_test_split(Xr,yr,test_size=.25,random_state=42)
reg_base=DummyRegressor(strategy='mean').fit(Xtr_r,ytr_r)
print('Baseline regressão (MAE):',round(mean_absolute_error(yte_r,reg_base.predict(Xte_r)),2))
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

A acurácia do baseline depende das proporções de classes; avaliar um modelo sem baseline não demonstra ganho real. Em agrupamento, números de cluster não são classes reais. Dados que mudam no tempo podem invalidar uma avaliação aleatória.

Perguntas de revisão:
- Qual hipótese implícita sustenta o procedimento usado?
- Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
- Como você mudaria o experimento para refletir dados reais?

Risco metodológico

É comum selecionar um algoritmo sofisticado antes de definir a métrica. Em classes desbalanceadas, um classificador constante pode apresentar grande acurácia e ainda ser inútil para detectar a classe rara.

7. Consulta rápida

• Supervisionado: pares (X,y); não supervisionado: estrutura em X.
• *Batch* ≠ *online*; instância ≠ modelo.
• Definir alvo, unidade de observação, métrica e cenário de uso ANTES de modelar.
• Conferir baseline e conjunto de teste independente.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: baseline e métrica. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema baseline e métrica pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Laboratório adicional — Baseline antes do algoritmo

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para baseline e métrica sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/