EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



02 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Matemática Aplicada a Machine Learning

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

Produto escalar, norma, projeção e distância aparecem em regressão, KNN, SVM e PCA. O cálculo computacional depende também do condicionamento das matrizes: variáveis correlacionadas podem produzir coeficientes instáveis mesmo quando previsões permanecem razoáveis. A padronização muda a geometria dos atributos e deve ser aprendida somente no conjunto de treino.

Ponto de atenção

Evite inverter matrizes diretamente para ajustar modelos sempre que houver um solucionador numérico mais estável. Uma transformação de escala não é automaticamente apropriada para todo algoritmo.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Usar vetores, matrizes, normas, distâncias, projeções, gradientes e regularização em problemas concretos.

Retomada de NumPy (Disciplina 01) e probabilidade (Disciplina 03), sem refazer seus capítulos. Produto escalar mede alinhamento; norma L2 mede comprimento; distância euclidiana é sensível à escala. Gradientes indicam direção de aumento local de uma função diferenciável; gradiente descendente atualiza parâmetros na direção oposta. Autovetores/autovalores serão retomados em PCA.

Interpretação prática

Produto escalar, norma, projeção e distância aparecem em regressão, KNN, SVM e PCA. O cálculo computacional depende também do condicionamento das matrizes: variáveis correlacionadas podem produzir coeficientes instáveis mesmo quando previsões permanecem razoáveis. A padronização muda a geometria dos atributos e deve ser aprendida somente no conjunto de treino.

2. Fundamentos matemáticos

lVert xrVert_2=sqrt{sum_j x_j^2}, d_2(x,z)=lVert x-zrVert_2 e x^top z=sum_jx_jz_j.

Para J(w)=fração1nsum_i (x_i^top w-y_i)^2, nabla J(w)=fração2n X^top(Xw-y). Com Ridge: J_lambda(w)=J(w)+lambdalVert wrVert_2^2 (intercepto não penalizado na prática).

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
import numpy as np
```

```
x=np.array([2.,1.]); z=np.array([4.,5.]);print('Produto escalar:',x@z,'normas:',np.linalg.no...
```

```
print('Distância:',np.linalg.norm(x-z))
```

```
A=np.array([[2.,0.],[0.,1.]])

values,vectors=np.linalg.eigh(A)

print('Autovalores:',values,'autovetores (colunas):\n',vectors)
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

O gradiente descendente demonstrado é uma implementação pedagógica de mínimos quadrados, não um otimizador universal. Sem normalização, um atributo de escala enorme pode dominar uma distância. Em modelos preditivos, o escalonador deve ser ajustado APENAS no treino.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Evite inverter matrizes diretamente para ajustar modelos sempre que houver um solucionador numérico mais estável. Uma transformação de escala não é automaticamente apropriada para todo algoritmo.

7. Consulta rápida

• @: produto matricial; np.linalg.norm: norma/distância.
• Derivada: taxa local de mudança; gradiente: vetor de derivadas parciais.
• Taxa de aprendizado excessiva pode causar divergência.
• Regularização penaliza complexidade, não resolve vazamento de dados.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: vetores e condicionamento. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema vetores e condicionamento pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para vetores e condicionamento sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/