EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



03 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Metodologia e Experimentos Preditivos

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

O conjunto de treino ajusta parâmetros; a validação orienta decisões e busca de hiperparâmetros; o teste reservado estima desempenho depois das escolhas. Dependência temporal, usuários repetidos e observações agrupadas exigem divisão por tempo ou grupo, não amostragem aleatória indiscriminada. Compare sempre com uma baseline usando a mesma partição.

Ponto de atenção

Data leakage surge quando o pré-processamento usa informações do conjunto de teste, quando há duplicações entre partições ou quando atributos contêm pistas posteriores ao evento previsto.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Formular hipótese, escolher baseline, planejar treino/validação/teste, evitar contaminação e selecionar divisões compatíveis com o problema.

O conjunto de teste representa avaliação final e não deve guiar a seleção de hiperparâmetros. train_test_split é útil para observações independentes; dados de uma pessoa/grupo ou dados temporais requerem outro esquema. A validação cruzada pertence ao treino e pode ser aninhada em problemas exigentes.

Interpretação prática

O conjunto de treino ajusta parâmetros; a validação orienta decisões e busca de hiperparâmetros; o teste reservado estima desempenho depois das escolhas. Dependência temporal, usuários repetidos e observações agrupadas exigem divisão por tempo ou grupo, não amostragem aleatória indiscriminada. Compare sempre com uma baseline usando a mesma partição.

2. Fundamentos matemáticos

Para um erro médio widehat R_{mathrm{teste}}=fração1msum_{i=1}^m L(y_i,hat f(x_i)), a qualidade da estimativa depende de como as observações de teste representam o uso futuro. Viés de seleção surge quando escolhemos o modelo após inspecionar repetidamente o teste.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_breast_cancer
```

```
from sklearn.model_selection import train_test_split, cross_val_score, StratifiedKFold
```

```
from sklearn.dummy import DummyClassifier
```

```
from sklearn.linear_model import LogisticRegression
```

```
X,y=load_breast_cancer(return_X_y=True)

Xtr,Xte,ytr,yte=train_test_split(X,y,test_size=.2,random_state=42,stratify=y)

cv=StratifiedKFold(5,shuffle=True,random_state=42)

model=LogisticRegression(max_iter=2000,solver='liblinear')

print('Baseline no treino:',round(DummyClassifier(strategy='most_frequent').fit(Xtr,ytr).sco...

print('Validação cruzada (somente treino):',cross_val_score(model,Xtr,ytr,cv=cv,scoring='bal...

model.fit(Xtr,ytr)

print('Teste final:',round(model.score(Xte,yte),3))
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

A estratificação ajuda a manter proporções, mas não remove dependência entre observações. A divisão temporal deve respeitar horizonte, *lag* e, quando necessário, intervalo de segurança (*gap*). O objetivo e o regime de avaliação precisam ser declarados antes do primeiro fit.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Data leakage surge quando o pré-processamento usa informações do conjunto de teste, quando há duplicações entre partições ou quando atributos contêm pistas posteriores ao evento previsto.

7. Consulta rápida

• Treino ajusta; validação compara; teste estima desempenho final.
• Grupos correlacionados exigem GroupKFold ou equivalente.
• Séries temporais: TimeSeriesSplit ou holdout cronológico.
• Reutilizar teste em iterações sucessivas contamina decisões.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: vazamento e divisão. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema vazamento e divisão pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Laboratório adicional — Vazamento e validação temporal

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para vazamento e divisão sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/