EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



05 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

KNN e Métodos Baseados em Distância

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

KNN armazena exemplos e realiza decisões locais. Com poucos vizinhos, a fronteira é irregular; com muitos, tende a suavizar diferenças. A escala das variáveis redefine proximidade: diferença de renda em milhares pode dominar uma distância que inclui idade em anos. Métricas euclidiana e Manhattan respondem a geometrias distintas.

Ponto de atenção

Uma melhora em validação não justifica escolher k com base no teste final. Em grande dimensão, vizinhos podem ficar pouco discriminativos; métodos aproximados alteram custos e eventualmente resultados.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Explicar vizinhança, escolha de k, ponderação, escalonamento e diferença entre KNN classificador e regressor.

KNN é baseado em instâncias: na predição, procura exemplos próximos e agrega seus rótulos. k pequeno aumenta sensibilidade local/variância; k grande pode produzir fronteiras excessivamente suaves. Distâncias euclidiana/manhattan têm geometrias diferentes. Em dimensões muito altas as distâncias podem se tornar menos informativas.

Interpretação prática

KNN armazena exemplos e realiza decisões locais. Com poucos vizinhos, a fronteira é irregular; com muitos, tende a suavizar diferenças. A escala das variáveis redefine proximidade: diferença de renda em milhares pode dominar uma distância que inclui idade em anos. Métricas euclidiana e Manhattan respondem a geometrias distintas.

2. Fundamentos matemáticos

d_1(x,z)=sum_j|x_j-z_j|; d_2(x,z)=sqrt{sum_j(x_j-z_j)^2}. Na classificação, hat y(x)={moda}{y_i:iin N_k(x)}; para regressão, usa-se média (ou média ponderada) dos vizinhos.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split,cross_val_score,StratifiedKFold
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
```

```
from sklearn.neighbors import KNeighborsClassifier

X,y=load_wine(return_X_y=True)

Xtr,Xte,ytr,yte=train_test_split(X,y,test_size=.25,stratify=y,random_state=42)

cv=StratifiedKFold(5,shuffle=True,random_state=42)

for k in [1,3,7,15]:

pipe=make_pipeline(StandardScaler(),KNeighborsClassifier(n_neighbors=k))

scores=cross_val_score(pipe,Xtr,ytr,cv=cv,scoring='balanced_accuracy')

print(f'k={k:2d}: {scores.mean():.3f} ± {scores.std():.3f}')
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Nunca escolher k observando a métrica do teste. KNN exige cuidado com escalas e demanda memória/tempo de previsão quando há muitas observações. Empates, pontos raros e atributos irrelevantes influenciam resultados.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Uma melhora em validação não justifica escolher k com base no teste final. Em grande dimensão, vizinhos podem ficar pouco discriminativos; métodos aproximados alteram custos e eventualmente resultados.

7. Consulta rápida

• n_neighbors: controla escala local.
• weights="distance" dá maior peso a vizinhos próximos.
• Escalonamento e validação devem estar no mesmo pipeline.
• Comparar desempenho com baseline e modelo paramétrico.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: escala de distância. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema escala de distância pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para escala de distância sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/