GUIA TÉCNICO

Naive Bayes e Classificação Probabilística

Propósito — Material didático autoral para revisão e estudo independente. Base: notebook correspondente e conceitos atualizados do scikit-learn.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

ROTEIRO DO DOCUMENTO

1. Conceitos e hipóteses
2. Fundamentos matemáticos
3. Experimento reproduzível
4. Interpretação e limitações
5. Exercícios orientados
6. Boas práticas de validação

01 | Contexto e decisões fundamentais

Naive Bayes usa P(classe|atributos) proporcional a P(classe) vezes o produto de probabilidades condicionais por atributo. O modelo simplifica ao supor independência condicional, raramente exata no mundo real. Pode ser competitivo com poucas observações ou características textuais, desde que a distribuição escolhida seja coerente.

Ponto de atenção

Uma probabilidade retornada pelo modelo não é necessariamente calibrada. Variáveis fortemente redundantes podem contar a mesma evidência mais de uma vez.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Transformar o Teorema de Bayes (Disciplina 03 — NB09) em um classificador, compreender independência condicional e diferenças entre GaussianNB, MultinomialNB e BernoulliNB.

Naive Bayes assume independência condicional à classe; isso é uma simplificação geralmente não verdadeira, mas pode resultar em boa classificação. GaussianNB modela atributos contínuos por gaussianas; MultinomialNB é comum para contagens; BernoulliNB, para atributos binários. A qualidade da decisão e a calibração probabilística são questões distintas.

Interpretação prática

Naive Bayes usa P(classe|atributos) proporcional a P(classe) vezes o produto de probabilidades condicionais por atributo. O modelo simplifica ao supor independência condicional, raramente exata no mundo real. Pode ser competitivo com poucas observações ou características textuais, desde que a distribuição escolhida seja coerente.

2. Fundamentos matemáticos

P(ymid x_1,ldots,x_p)propto P(y)prod_{j=1}^pP(x_jmid y). O classificador escolhe a classe com maior produto (na implementação, somam-se log-probabilidades por estabilidade numérica). Em GaussianNB, cada P(x_jmid y) segue uma densidade normal estimada por classe.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_iris
```

```
from sklearn.model_selection import train_test_split
```

```
from sklearn.naive_bayes import GaussianNB
```

```
from sklearn.metrics import classification_report,confusion_matrix
```

```
X,y=load_iris(return_X_y=True)
a,b,c,d=train_test_split(X,y,test_size=.25,stratify=y,random_state=42)
clf=GaussianNB().fit(a,c)
print('Prioris aprendidas:',clf.class_prior_.round(3))
print('Matriz de confusão:\n',confusion_matrix(d,clf.predict(b)))
print(classification_report(d,clf.predict(b),zero_division=0))
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Probabilidades preditas podem estar mal calibradas; não usá-las como certezas. A escolha da variante depende da natureza das variáveis e de suas suposições, não apenas da performance pontual.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Uma probabilidade retornada pelo modelo não é necessariamente calibrada. Variáveis fortemente redundantes podem contar a mesma evidência mais de uma vez.

7. Consulta rápida

• Bayes (03) é fundamento; Naive Bayes (05) é algoritmo.
• Gaussian: atributos contínuos; Multinomial: contagens não negativas; Bernoulli: binários.
• alpha controla suavização nas variantes discreta.
• Validar com métricas apropriadas e comparar com regressão logística.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: independência condicional. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema independência condicional pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para independência condicional sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/