EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



07 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Regressão Logística para Classificação

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

A regressão logística estima probabilidade através da função sigmoide aplicada a um preditor linear. Coeficientes atuam sobre log-odds, não sobre variações absolutas da probabilidade. A força da regularização e a transformação dos atributos influenciam o ajuste; a escolha do limiar de decisão deve refletir o custo de falsos negativos e positivos.

Ponto de atenção

Classificação binária não exige sempre o limiar padrão 0,5. Interpretar coeficiente como efeito causal sem desenho de identificação é incorreto.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Conectar GLM/logit da Disciplina 03 à classificação preditiva, explicar regularização, probabilidades, limiares e interpretação.

Apesar do nome, regressão logística é usualmente classificador. Seus coeficientes operam nos *log-odds*, não diretamente em probabilidades. predict_proba produz estimativas que podem exigir calibração; predict escolhe classes conforme regra padrão de decisão. A regularização controla complexidade.

Interpretação prática

A regressão logística estima probabilidade através da função sigmoide aplicada a um preditor linear. Coeficientes atuam sobre log-odds, não sobre variações absolutas da probabilidade. A força da regularização e a transformação dos atributos influenciam o ajuste; a escolha do limiar de decisão deve refletir o custo de falsos negativos e positivos.

2. Fundamentos matemáticos

p(y=1mid x)=sigma(beta_0+x^topbeta), onde sigma(t)=1/(1+e^{-t}). O logit é logfração p{1-p}=beta_0+x^topbeta. Perda logística binária: -fração1nsum_i[y_ilog p_i+(1-y_i)log(1-p_i)].

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_breast_cancer
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
```

```
from sklearn.metrics import roc_auc_score,precision_recall_fscore_support
X,y=load_breast_cancer(return_X_y=True)
a,b,c,d=train_test_split(X,y,stratify=y,test_size=.25,random_state=42)
pipe=make_pipeline(StandardScaler(),LogisticRegression(C=1.,max_iter=2000)).fit(a,c)
proba=pipe.predict_proba(b)[:,1]
print('ROC AUC:',round(roc_auc_score(d,proba),3))
for t in [.3,.5,.7]:
precision,recall,f1,_=precision_recall_fscore_support(d,proba>=t,average='binary',zero_d...
print('threshold',t,'precision',round(precision,3),'recall',round(recall,3),'f1',round(f...
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Coeficientes não representam causalidade. Tuning de limiar deve usar validação e nunca o teste final. Em contexto de saúde, nomes de classes e custos dos erros precisam ser explicitados antes de decidir o limiar.

Perguntas de revisão:
- Qual hipótese implícita sustenta o procedimento usado?
- Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
- Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Classificação binária não exige sempre o limiar padrão 0,5. Interpretar coeficiente como efeito causal sem desenho de identificação é incorreto.

7. Consulta rápida

- C é inversamente relacionado à força da regularização.
- Escalonar antes da penalização, dentro do pipeline.
- roc_auc_score usa scores/probabilidades, não rótulos binários.
- Coeficientes dependem de escala e colinearidade.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: probabilidade calibrada. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema probabilidade calibrada pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para probabilidade calibrada sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/