EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



08 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Máquinas de Vetores de Suporte

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

SVM busca uma fronteira com margem ampla, penalizando violações de acordo com C. Kernels representam relações não lineares via similaridades; o kernel RBF depende fortemente de gamma e da escala dos atributos. C alto pode tolerar menos violações e produzir ajuste mais rígido.

Ponto de atenção

Valores de C e gamma devem ser selecionados por validação. A SVM não fornece probabilidades calibradas por definição; avaliar escala e dimensão é essencial.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Entender hiperplano de margem máxima, vetores de suporte, margem suave, kernels, C e gamma.

Uma SVM linear escolhe fronteira com margem ampla, tolerando violações em casos não separáveis. Kernel RBF permite fronteiras não lineares por produto interno implícito em espaço de características. SVM é sensível à escala e pode ser dispendiosa em datasets extensos.

Interpretação prática

SVM busca uma fronteira com margem ampla, penalizando violações de acordo com C. Kernels representam relações não lineares via similaridades; o kernel RBF depende fortemente de gamma e da escala dos atributos. C alto pode tolerar menos violações e produzir ajuste mais rígido.

2. Fundamentos matemáticos

Hiperplano w^top x+b=0. Uma forma de otimização de margem suave é min_{w,b,xi}fração12lVert wrVert^2+Csum_ixi_i sujeito a y_i(w^top x_i+b)ge1-xi_i e xi_ige0. Kernel RBF: K(x,z)=exp(-gammalVert x-zrVert_2^2).

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import make_moons
from sklearn.model_selection import train_test_split,cross_val_score
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
X,y=make_moons(n_samples=300,noise=.20,random_state=42)
```

```
a,b,c,d=train_test_split(X,y,stratify=y,test_size=.25,random_state=42)

for kernel in ['linear','rbf']:

model=make_pipeline(StandardScaler(),SVC(kernel=kernel,C=1.,gamma='scale')).fit(a,c)

print(kernel,'treino',round(model.score(a,c),3),'teste',round(model.score(b,d),3),'vetor...
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

C alto penaliza violações; não garante melhor generalização. gamma alto restringe influência local no RBF, podendo sobreajustar. Para regressão com margem epsilon, veja o capítulo 13 sobre SVR.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Valores de C e gamma devem ser selecionados por validação. A SVM não fornece probabilidades calibradas por definição; avaliar escala e dimensão é essencial.

7. Consulta rápida

• SVC: classificação; SVR: regressão.
• Usar StandardScaler em Pipeline.
• Kernels: linear e RBF são pontos de partida.
• Escolher C/gamma por validação, não pelo teste.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: margem e escala. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema margem e escala pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para margem e escala sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/