GUIA TÉCNICO

Árvores de Decisão, Random Forest e Boosting

Propósito — Material didático autoral para revisão e estudo independente. Base: notebook correspondente e conceitos atualizados do scikit-learn.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

ROTEIRO DO DOCUMENTO

1. Conceitos e hipóteses
2. Fundamentos matemáticos
3. Experimento reproduzível
4. Interpretação e limitações
5. Exercícios orientados
6. Boas práticas de validação

01 | Contexto e decisões fundamentais

Árvores dividem o espaço por regras e capturam interações sem escalonamento obrigatório. Árvores profundas podem memorizar ruído. Random Forest usa diversificação por amostras e atributos para reduzir variância; boosting constrói uma sequência de correções e exige controle de complexidade e taxa de aprendizagem.

Ponto de atenção

Importâncias baseadas em impureza podem favorecer atributos com muitos pontos de corte. Faça inferências sobre relevância com conjunto de avaliação e controle de correlação.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Explicar divisão recursiva, Gini/entropia, poda, bagging, Random Forest e boosting; comparar classificação e regressão por árvores.

Árvores podem capturar interações e não linearidades sem escalonamento obrigatório. Árvores profundas são instáveis; Random Forest combina árvores treinadas sobre amostras e subconjuntos aleatórios de atributos. Boosting combina estimadores sequenciais que corrigem erros do conjunto. Importâncias baseadas em impureza podem favorecer atributos com muitas possibilidades de corte.

Interpretação prática

Árvores dividem o espaço por regras e capturam interações sem escalonamento obrigatório. Árvores profundas podem memorizar ruído. Random Forest usa diversificação por amostras e atributos para reduzir variância; boosting constrói uma sequência de correções e exige controle de complexidade e taxa de aprendizagem.

2. Fundamentos matemáticos

Impureza de Gini G=1-sum_k p_k^2 e entropia H=-sum_k p_klog_2p_k. Para regressão, um critério usual é a redução de erro quadrático. No bagging, hat f(x)=fração1Bsum_{b=1}^B f_b(x) para regressão (ou votação para classificação).

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_wine

from sklearn.model_selection import train_test_split

from sklearn.tree import DecisionTreeClassifier

from sklearn.ensemble import RandomForestClassifier,HistGradientBoostingClassifier
```

```
from sklearn.metrics import balanced_accuracy_score
X,y=load_wine(return_X_y=True);a,b,c,d=train_test_split(X,y,stratify=y,test_size=.3,random_s...
models={'árvore':DecisionTreeClassifier(max_depth=4,random_state=42),'forest':RandomForestCl...
for name,m in models.items():
m.fit(a,c);print(name,'balanced_accuracy',round(balanced_accuracy_score(d,m.predict(b)),3))
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Não inferir causalidade com importância de atributos. Valores altos de treino e baixos de teste indicam possível overfitting. HistGradientBoosting fornece baseline moderno sem adicionar XGBoost como dependência obrigatória.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Importâncias baseadas em impureza podem favorecer atributos com muitos pontos de corte. Faça inferências sobre relevância com conjunto de avaliação e controle de correlação.

7. Consulta rápida

• Árvore: interpretável localmente, frequentemente instável.
• Random Forest: bagging + aleatoriedade de atributos.
• Boosting: processo sequencial de melhora do conjunto.
• max_depth, min_samples_leaf e regularização são hiperparâmetros importantes.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: viés-variância. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema viés-variância pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para viés-variância sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/