GUIA TÉCNICO

Avaliação de Classificadores e Desbalanceamento

Propósito — Material didático autoral para revisão e estudo independente. Base: notebook correspondente e conceitos atualizados do scikit-learn.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

ROTEIRO DO DOCUMENTO

1. Conceitos e hipóteses
2. Fundamentos matemáticos
3. Experimento reproduzível
4. Interpretação e limitações
5. Exercícios orientados
6. Boas práticas de validação

01 | Contexto e decisões fundamentais

Accuracy, precision, recall e F1 respondem a perguntas distintas. ROC-AUC resume ordenação em diferentes limiares, enquanto average precision ajuda a caracterizar recuperação de classes raras. A matriz de confusão explicita quantos erros de cada tipo ocorreram. Escolha a métrica antes de comparar algoritmos.

Ponto de atenção

Rebalancear dados antes da separação pode contaminar validação. Um escore agregado pode esconder degradação em subgrupos e necessidades de calibração.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Medir e interpretar erros por classe, curvas ROC/PR, acurácia balanceada, decisões por limiar e desbalanceamento.

Matriz de confusão descreve erros; precisão (precision) responde quanto das previsões positivas foi positivo; sensibilidade (recall) responde quanto dos verdadeiros positivos foi encontrado. Em problemas raros, acurácia pode ser enganosa. Reamostragem só pode ser aplicada ao treino e dentro de cada fold de validação; imbalanced-learn será opcional.

Interpretação prática

Accuracy, precision, recall e F1 respondem a perguntas distintas. ROC-AUC resume ordenação em diferentes limiares, enquanto average precision ajuda a caracterizar recuperação de classes raras. A matriz de confusão explicita quantos erros de cada tipo ocorreram. Escolha a métrica antes de comparar algoritmos.

2. Fundamentos matemáticos

mathrm{precision}=TP/(TP+FP), mathrm{recall}=TP/(TP+FN), F_1=2PR/(P+R) e mathrm{balanced accuracy}=fração12(TPR+TNR) em problema binário. Valores com denominador zero exigem uma convenção explicitada.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import make_classification
```

```
from sklearn.model_selection import train_test_split
```

```
from sklearn.dummy import DummyClassifier
```

```
from sklearn.pipeline import make_pipeline
```

```
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report,confusion_matrix,roc_auc_score,average_pre...
X,y=make_classification(n_samples=700,n_features=10,weights=[.94,.06],random_state=42)
a,b,c,d=train_test_split(X,y,test_size=.3,stratify=y,random_state=42)
for name,model in [('dummy',DummyClassifier(strategy='most_frequent')),('logit',make_pipelin...
model.fit(a,c);pred=model.predict(b)
print(name,'acc_bal',round(balanced_accuracy_score(d,pred),3),'matriz:\n',confusion_matr...
print(classification_report(d,pred,zero_division=0))
if hasattr(model,'predict_proba'):
proba=model.predict_proba(b)[:,1]
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

AUC não resume qualidade de probabilidades; calibração é separada. Um threshold precisa ser escolhido na validação segundo custos do problema. Se usar SMOTE, colocá-lo em imblearn.pipeline.Pipeline exclusivamente dentro do treinamento/validação; não aplicá-lo ao teste.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Rebalancear dados antes da separação pode contaminar validação. Um escore agregado pode esconder degradação em subgrupos e necessidades de calibração.

7. Consulta rápida

• Conferir qual classe é positiva.
• Acurácia alta pode coexistir com recall da classe rara igual a zero.
• Curva PR e average precision são úteis para eventos raros.
• Reamostragem antes do split ou CV causa contaminação.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: limiares e desbalanceamento. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema limiares e desbalanceamento pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Laboratório adicional — Matriz de confusão e trade-off do limiar

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para limiares e desbalanceamento sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/