GUIA TÉCNICO

# Validação Cruzada, Seleção e Otimização

Propósito — Material didático autoral para revisão e estudo independente. Base: notebook correspondente e conceitos atualizados do scikit-learn.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

## ROTEIRO DO DOCUMENTO

1. Conceitos e hipóteses
2. Fundamentos matemáticos
3. Experimento reproduzível
4. Interpretação e limitações
5. Exercícios orientados
6. Boas práticas de validação

## 01 | Contexto e decisões fundamentais

Cross-validation aproxima o desempenho usando múltiplas partições; o método de particionamento deve respeitar estratificação, tempo e grupos. GridSearchCV avalia combinações no treino, mas sua melhor pontuação tende a ser otimista após muitas tentativas. Para estimar o processo completo de seleção, prefira avaliação externa reservada ou nested CV.

### Ponto de atenção

Nunca relatar o melhor score interno da busca como desempenho final em dados inéditos. Muitas comparações sobre o mesmo teste acabam transformando-o implicitamente em validação.

## 02 | Fundamentação e hipóteses

## 1. Fundamentos, objetivos e contexto

Objetivos. Projetar busca de hiperparâmetros com pipelines, entender GridSearchCV, RandomizedSearchCV, validação estratificada/por grupos/temporal e noções de validação aninhada.

### Interpretação prática

Cross-validation aproxima o desempenho usando múltiplas partições; o método de particionamento deve respeitar estratificação, tempo e grupos. GridSearchCV avalia combinações no treino, mas sua melhor pontuação tende a ser otimista após muitas tentativas. Para estimar o processo completo de seleção, prefira avaliação externa reservada ou nested CV.

## 2. Fundamentos matemáticos

Para K folds, mathrm{CV}(theta)=fração1Ksum_{k=1}^Kwidehat R_k(theta). A escolha hat theta=argmin_thetamathrm{CV}(theta) depende dos mesmos folds avaliados; para estimar sem esse viés de seleção, usar um teste independente (ou validação aninhada).

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

## 3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

### Exemplo reproduzível selecionado

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split,GridSearchCV,StratifiedKFold
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import balanced_accuracy_score
X,y=load_wine(return_X_y=True)
```

**EXEMPLO COMPLETO NO APÊNDICE**

O código integral está no apêndice deste guia, em formato copiável e sem linhas truncadas.

### Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

## 4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

## 5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

## 6. Interpretação, limitações e erros comuns

A busca exaustiva pode ficar cara em espaços grandes. n_jobs=1 aqui evita excesso de memória no computador de 8 GB. Em dados temporais ou agrupados, substituir os folds padrão por esquemas adequados.

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

### Risco metodológico

Nunca relatar o melhor score interno da busca como desempenho final em dados inéditos. Muitas comparações sobre o mesmo teste acabam transformando-o implicitamente em validação.

## 7. Consulta rápida

• GridSearchCV: grade fixa; RandomizedSearchCV: amostragem de combinações.
• scoring deve representar a decisão de negócio.
• Teste é avaliação final, não um instrumento de tuning.
• Registrar random_state, versões e tempo de execução.

## Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

## Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: seleção aninhada. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema seleção aninhada pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

### Laboratório adicional — Validação cruzada estratificada

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

### Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para seleção aninhada sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

## Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

### Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/

# APÊNDICE — CÓDIGO REPRODUZÍVEL (1/1)

Fonte: 11_validacao_otimizacao.ipynb

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split,GridSearchCV,StratifiedKFold
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import balanced_accuracy_score
X,y=load_wine(return_X_y=True)
a,b,c,d=train_test_split(X,y,test_size=.25,stratify=y,random_state=42)
pipe=make_pipeline(StandardScaler(),KNeighborsClassifier())
grid=GridSearchCV(pipe,{'kneighborsclassifier__n_neighbors':[3,5,7,9],
    'kneighborsclassifier__weights':['uniform','distance']},cv=StratifiedKFold(4,
    shuffle=True,random_state=42),scoring='balanced_accuracy',n_jobs=1)
grid.fit(a,c)
print('Melhores parâmetros:',grid.best_params_,'CV:',round(grid.best_score_,3))
print('Teste final (uma vez):',round(balanced_accuracy_score(d,grid.predict(b)),3))
```