EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



12 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Regressão Linear, Múltipla e Regularização

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

Regressão linear modela a resposta como soma ponderada de atributos e termo independente. Resíduos revelam curvatura, heterocedasticidade e pontos influentes. Ridge estabiliza coeficientes por penalização quadrática; Lasso pode zerar coeficientes; Elastic Net combina penalidades. O RMSE reage mais a erros grandes do que o MAE.

Ponto de atenção

Coeficiente significativo não equivale a causalidade. Ajuste linear pode prever valores implausíveis fora do domínio observado; faça diagnóstico da distribuição de resíduos.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Revisar equação de regressão (Disciplina 03), aplicar validação preditiva, entender Ridge/Lasso/Elastic Net e interpretação de coeficientes.

Mínimos quadrados ajustam média condicional sob função de perda quadrática. Predição não exige necessariamente que todos os pressupostos inferenciais clássicos sejam verdadeiros, mas desvios afetam interpretação e incerteza. Regularização é útil com colinearidade e muitos atributos; os coeficientes dependem da escala.

Interpretação prática

Regressão linear modela a resposta como soma ponderada de atributos e termo independente. Resíduos revelam curvatura, heterocedasticidade e pontos influentes. Ridge estabiliza coeficientes por penalização quadrática; Lasso pode zerar coeficientes; Elastic Net combina penalidades. O RMSE reage mais a erros grandes do que o MAE.

2. Fundamentos matemáticos

Modelo hat y=beta_0+Xbeta; OLS minimiza sum_i(y_i-hat y_i)^2. Ridge acrescenta alphalVertbetarVert_2^2; Lasso acrescenta alphalVertbetarVert_1; Elastic Net combina ambas. O intercepto geralmente não é penalizado.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_diabetes
```

```
from sklearn.model_selection import train_test_split,cross_val_score,KFold
```

```
from sklearn.preprocessing import StandardScaler
```

```
from sklearn.pipeline import make_pipeline
```

```
from sklearn.linear_model import LinearRegression,Ridge,Lasso,ElasticNet
from sklearn.metrics import mean_absolute_error,r2_score
X,y=load_diabetes(return_X_y=True)
a,b,c,d=train_test_split(X,y,test_size=.25,random_state=42)
for reg in [LinearRegression(),Ridge(alpha=1.),Lasso(alpha=.1,max_iter=10000),ElasticNet(alp...
p=make_pipeline(StandardScaler(),reg).fit(a,c)
pred=p.predict(b)
print(type(reg).__name__,'MAE',round(mean_absolute_error(d,pred),2),'R2',round(r2_score(...
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

R^2 pode ser negativo no teste. OLS não é apropriado como prova de causalidade. Regularização exige escolha de intensidade por validação, não por menor erro de treino.

Perguntas de revisão:

- Qual hipótese implícita sustenta o procedimento usado?
- Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
- Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Coeficiente significativo não equivale a causalidade. Ajuste linear pode prever valores implausíveis fora do domínio observado; faça diagnóstico da distribuição de resíduos.

7. Consulta rápida

- OLS otimiza MSE; Ridge usa L2; Lasso usa L1; Elastic Net combina.
- MAE é mais robusto a erros grandes do que RMSE.
- Validar com holdout apropriado e analisar resíduos.
- Coeficientes não equivalem a efeitos causais.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: resíduos e intervalos. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema resíduos e intervalos pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para resíduos e intervalos sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/