EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



13 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Regressão Não Linear e Avaliação de Regressores

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

Termos polinomiais, SVR e modelos baseados em árvores introduzem não linearidade de formas diferentes. A validação dentro do domínio observado não garante extrapolação confiável. Compare desempenho sob múltiplas regiões do espaço de entrada, e explicite a região de validade das predições.

Ponto de atenção

Alta flexibilidade pode reduzir erro de treino sem melhorar generalização. Dividir aleatoriamente séries temporais costuma produzir estimativas otimistas.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Comparar transformações polinomiais, SVR, árvores e Random Forest em regressão; interpretar MAE, MSE, RMSE, R^2 e resíduos.

Regressão polinomial é linear nos coeficientes após a transformação dos atributos. Transformação de grau alto favorece sobreajuste. SVR controla tolerância epsilon e regularização C. Para séries temporais, não misturar observações futuras no treinamento.

Interpretação prática

Termos polinomiais, SVR e modelos baseados em árvores introduzem não linearidade de formas diferentes. A validação dentro do domínio observado não garante extrapolação confiável. Compare desempenho sob múltiplas regiões do espaço de entrada, e explicite a região de validade das predições.

2. Fundamentos matemáticos

mathrm{MAE}=fração1nsum|y_i-hat y_i|; mathrm{MSE}=fração1nsum(y_i-hat y_i)^2; mathrm{RMSE}=sqrt{mathrm{MSE}}; R^2=1-fração{sum (y_i-hat y_i)^2}{sum(y_i-bar y)^2}.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
import numpy as np
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import PolynomialFeatures,StandardScaler
from sklearn.linear_model import Ridge
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_absolute_error,root_mean_squared_error,r2_score
```

```
rng=np.random.default_rng(42)
X=rng.uniform(-2,2,size=(240,1));y=1+2*X[:,0]-1.5*X[:,0]**2+rng.normal(0,.45,240)
a,b,c,d=train_test_split(X,y,test_size=.25,random_state=42)
for degree in [1,2,8]:
m=make_pipeline(PolynomialFeatures(degree=degree,include_bias=False),StandardScaler(),Ri...
p=m.predict(b)
print('grau',degree,'MAE',round(mean_absolute_error(d,p),3),'RMSE',round(root_mean_squar...
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Perguntas de revisão:

- Qual hipótese implícita sustenta o procedimento usado?
- Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
- Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Alta flexibilidade pode reduzir erro de treino sem melhorar generalização. Dividir aleatoriamente séries temporais costuma produzir estimativas otimistas.

7. Consulta rápida

- Polinomial: transformação de entrada + regressor linear.
- SVR: regressão por vetores de suporte.
- Árvores e Random Forest também fazem regressão.
- Escolher métrica conforme unidades, custo dos erros e cenário.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: extrapolação. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema extrapolação pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para extrapolação sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/