EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



14 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

PCA, Seleção e Redução de Dimensionalidade

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

PCA identifica direções ortogonais de máxima variância e projeta os atributos, usualmente após padronização. Componentes são combinações lineares e não possuem interpretação causal direta. Como método não supervisionado, PCA não otimiza necessariamente a previsão do alvo. Se usado na modelagem, deve estar dentro do pipeline e da validação.

Ponto de atenção

Escolher o número de componentes pela variância retida pode descartar direções de baixa variância úteis à previsão. Não confunda seleção supervisionada com PCA.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Explicar autovetores/autovalores, variância explicada, projeções, redução de dimensionalidade, seleção de atributos e vazamento.

PCA encontra direções ortogonais de maior variância dos dados centrados (e frequentemente escalonados); não usa rótulos. Alta variância não significa automaticamente alta relevância preditiva. Seleção de atributos escolhe colunas; PCA constrói combinações. Ambos devem ser ajustados somente no treino quando usados em modelo supervisionado.

Interpretação prática

PCA identifica direções ortogonais de máxima variância e projeta os atributos, usualmente após padronização. Componentes são combinações lineares e não possuem interpretação causal direta. Como método não supervisionado, PCA não otimiza necessariamente a previsão do alvo. Se usado na modelagem, deve estar dentro do pipeline e da validação.

2. Fundamentos matemáticos

Para matriz centrada X_c, matriz de covariância Sigma=X_c^top X_c/(n-1). PCA usa autovetores v_j de Sigma com autovalores lambda_j decrescentes. Variância explicada proporcional: lambda_j/sum_klambda_k.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_wine
```

```
from sklearn.model_selection import train_test_split,cross_val_score,StratifiedKFold
```

```
from sklearn.pipeline import make_pipeline
```

```
from sklearn.preprocessing import StandardScaler
```

```
from sklearn.decomposition import PCA
from sklearn.linear_model import LogisticRegression
X,y=load_wine(return_X_y=True)
a,b,c,d=train_test_split(X,y,test_size=.25,stratify=y,random_state=42)
pipe=make_pipeline(StandardScaler(),PCA(n_components=.95),LogisticRegression(max_iter=1500))...
pca=pipe.named_steps['pca'];print('Componentes para 95%:',pca.n_components_,'variância acumu...
print('Teste:',round(pipe.score(b,d),3))
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

PCA pode prejudicar interpretação, pois componentes misturam variáveis. O percentual de variância preservada não mede diretamente desempenho preditivo. Se usar PCA em validação cruzada, colocá-lo dentro do pipeline para evitar vazamento.

Perguntas de revisão:
- Qual hipótese implícita sustenta o procedimento usado?
- Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
- Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Escolher o número de componentes pela variância retida pode descartar direções de baixa variância úteis à previsão. Não confunda seleção supervisionada com PCA.

7. Consulta rápida

- PCA é não supervisionado; seleção de atributos pode ser supervisionada.
- Ajustar PCA e SelectKBest apenas dentro do treino/folds.
- Padronizar atributos com unidades muito distintas.
- Documentar trade-off desempenho × interpretabilidade.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: variância explicada. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema variância explicada pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para variância explicada sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/