EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



15 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

K-Means e Agrupamento Hierárquico

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

K-Means minimiza dispersão quadrática dentro de k grupos e tende a preferir estruturas compactas. Hierárquico produz uma árvore de fusões cujos resultados dependem da métrica e do linkage. Sem rótulos, não existe uma verdade de classe a ser recuperada automaticamente. Avalie estabilidade, utilidade e distribuição de tamanhos.

Ponto de atenção

Escolher k exclusivamente pelo silhouette score pode ignorar relevância de negócio e grupos pequenos importantes. Centroides sofrem influência de outliers.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Distinguir clustering de classificação, explicar centróides, inércia, dendrogramas, distância e ligação (*linkage*).

K-Means procura grupos compactos em torno de centróides e depende da escala, inicialização e escolha de k. Clustering hierárquico constrói estrutura de fusões, representada por dendrograma. Rótulos de clusters são arbitrários e não devem ser comparados diretamente a rótulos de classes sem correspondência apropriada.

Interpretação prática

K-Means minimiza dispersão quadrática dentro de k grupos e tende a preferir estruturas compactas. Hierárquico produz uma árvore de fusões cujos resultados dependem da métrica e do linkage. Sem rótulos, não existe uma verdade de classe a ser recuperada automaticamente. Avalie estabilidade, utilidade e distribuição de tamanhos.

2. Fundamentos matemáticos

Objetivo K-Means: min_{C_1,ldots,C_k,mu_1,ldots,mu_k}sum_{j=1}^ksum_{x_iin C_j}lVert x_i-mu_jrVert_2^2. A inércia diminui ou não aumenta quando k aumenta; isso não torna sempre desejável escolher k máximo.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import make_blobs
from sklearn.cluster import KMeans,AgglomerativeClustering
from sklearn.metrics import silhouette_score
from sklearn.preprocessing import StandardScaler
```

```
X,_=make_blobs(n_samples=220,centers=3,cluster_std=.7,random_state=42)
X=StandardScaler().fit_transform(X) # Exploratório, sem teste preditivo
for k in [2,3,4,5]:
km=KMeans(n_clusters=k,n_init=10,random_state=42).fit(X)
print('k',k,'inércia',round(km.inertia_,2),'silhouette',round(silhouette_score(X,km.labe...
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Silhouette favorece certa geometria de clusters e não garante valor substantivo. Variáveis irrelevantes e escala podem dominar. Hierarquia com método Ward assume distância euclidiana e costuma favorecer grupos aproximadamente compactos.

Perguntas de revisão:
- Qual hipótese implícita sustenta o procedimento usado?
- Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
- Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Escolher k exclusivamente pelo silhouette score pode ignorar relevância de negócio e grupos pequenos importantes. Centroides sofrem influência de outliers.

7. Consulta rápida

- KMeans: particional; AgglomerativeClustering: hierárquico.
- Inércia não seleciona automaticamente k ótimo.
- silhouette_score: qualidade interna, não prova de classes reais.
- Dendrograma mostra sequência de fusões.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: escolha de k. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema escolha de k pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para escolha de k sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/