EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE

16 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

DBSCAN e Avaliação de Agrupamentos

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

DBSCAN identifica regiões densas conectadas, separando pontos isolados como ruído. Os parâmetros eps e min_samples dependem de escala, dimensão e densidade. Pode detectar formatos não convexos, diferentemente do K-Means, mas sofre quando clusters possuem densidades muito distintas.

Ponto de atenção

O rótulo -1 representa ruído segundo os parâmetros escolhidos, não necessariamente anomalia real. Silhouette exige cuidados quando há um único grupo ou grande proporção de ruído.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Objetivos. Entender grupos por densidade, parâmetros eps e min_samples, pontos núcleo/borda/ruído, e métricas internas/externas.

DBSCAN identifica regiões densas e pode apontar ruído com rótulo -1. É útil para formas não convexas, mas sensível à escala e à escolha de eps; densidades muito diferentes em um mesmo dataset são um desafio. Métricas externas como ARI usam rótulos verdadeiros quando existentes; silhouette não é definida para menos de dois clusters válidos.

Interpretação prática

DBSCAN identifica regiões densas conectadas, separando pontos isolados como ruído. Os parâmetros eps e min_samples dependem de escala, dimensão e densidade. Pode detectar formatos não convexos, diferentemente do K-Means, mas sofre quando clusters possuem densidades muito distintas.

2. Fundamentos matemáticos

Definição intuitiva: um ponto núcleo tem pelo menos min_samples observações na sua vizinhança $N_{\varepsilon}(x)=\{z:d(x,z)\le\varepsilon\}$ (incluindo o próprio ponto em implementações usuais). Silhouette individual: $s(i)=(b(i)-a(i))/\max\{a(i),b(i)\}$.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import make_moons
from sklearn.cluster import DBSCAN,KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import adjusted_rand_score,silhouette_score
import numpy as np
```

```
X,y=make_moons(n_samples=300,noise=.06,random_state=42)
X=StandardScaler().fit_transform(X)
for eps in [.15,.25,.4]:
labels=DBSCAN(eps=eps,min_samples=5).fit_predict(X)
n_clusters=len(set(labels)-{-1});noise=(labels==-1).sum()
ari=adjusted_rand_score(y,labels)
print('eps',eps,'clusters',n_clusters,'ruído',noise,'ARI (comparação didática)',round(ar...
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Métricas externas requerem rótulos de referência e só fazem sentido em experimentos onde eles existem. Silhouette pode ter interpretação ruim para estruturas não convexas como luas. DBSCAN não atribui automaticamente novos pontos por predict no estimador padrão.

Perguntas de revisão:
- Qual hipótese implícita sustenta o procedimento usado?
- Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
- Como você mudaria o experimento para refletir dados reais?

Risco metodológico

O rótulo -1 representa ruído segundo os parâmetros escolhidos, não necessariamente anomalia real. Silhouette exige cuidados quando há um único grupo ou grande proporção de ruído.

7. Consulta rápida

- eps: raio de vizinhança; min_samples: densidade mínima.
- Ruído recebe -1.
- Escalonamento e distância mudam a definição de densidade.
- Avaliação interna não é sinônimo de validação científica dos grupos.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: ruído e densidade. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema ruído e densidade pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para ruído e densidade sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/