EDUARDO JUNIOR PEREIRA | EP • DATA SCIENCE KNOWLEDGE BASE



17 / DATA SCIENCE / MACHINE LEARNING I

GUIA TÉCNICO EP / APRENDIZADO DE MÁQUINA I

Interpretação, Robustez e Reprodutibilidade

Fundamentação conceitual, demonstrações e interpretação metodológica.

MAPA DE ESTUDO

01 Conceitos e hipóteses

02 Fundamentos matemáticos

03 Experimento reproduzível

04 Interpretação e limitações

05 Exercícios orientados

06 Boas práticas de validação

Material didático autoral para revisão e estudo independente.

Base: notebook correspondente e conceitos atualizados do scikit-learn.

01 | Contexto e decisões fundamentais

Permutation importance mede queda de desempenho quando uma variável é perturbada e depende do conjunto de avaliação e da métrica. Atributos correlacionados repartem informação e podem produzir importâncias baixas individualmente. Reprodutibilidade requer registrar versões, sementes, dados, partições, parâmetros e artefatos.

Ponto de atenção

Uma explicação de modelo não prova causalidade. Compare estabilidade das importâncias, repita avaliações e registre limites da população e do período estudados.

02 | Fundamentação e hipóteses

1. Fundamentos, objetivos e contexto

Interpretação de modelo não é inferência causal. Importância por permutação mede queda de desempenho ao perturbar atributo sob métrica e dados definidos; atributos correlacionados podem dividir relevância. Avaliar por subgrupos pode revelar comportamento desigual, mas atributos sensíveis requerem cuidado ético e autorização. *Drift* pode tornar o desempenho histórico inadequado para dados futuros.

Interpretação prática

Permutation importance mede queda de desempenho quando uma variável é perturbada e depende do conjunto de avaliação e da métrica. Atributos correlacionados repartem informação e podem produzir importâncias baixas individualmente. Reprodutibilidade requer registrar versões, sementes, dados, partições, parâmetros e artefatos.

2. Fundamentos matemáticos

Importância por permutação de j: I_j=mathrm{score}(D,hat f)-fração1Rsum_{r=1}^Rmathrm{score}(pi_{j,r}(D),hat f). Estimativa condicionada ao conjunto avaliado, à métrica e à permutação, não um efeito causal.

Conexão com disciplinas anteriores: revise os conceitos matemáticos e estatísticos correspondentes. Não repetimos integralmente os capítulos de Python, visualização e inferência estatística.

3. Experimento guiado: preparando a pergunta

Antes do código, identifique: (a) quais dados são de treino, (b) qual informação poderá entrar no modelo, (c) que métrica ou propriedade será observada, e (d) que conclusão não é permitida pelos resultados. Estes exemplos são didáticos, com semente fixa onde aplicável.

Exemplo reproduzível selecionado

```
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.inspection import permutation_importance
from sklearn.metrics import balanced_accuracy_score,confusion_matrix
```

```
import numpy as np
X,y=load_breast_cancer(return_X_y=True)
a,b,c,d=train_test_split(X,y,test_size=.3,stratify=y,random_state=42)
m=RandomForestClassifier(n_estimators=75,random_state=42,n_jobs=1).fit(a,c)
imp=permutation_importance(m,b,d,n_repeats=3,scoring='balanced_accuracy',random_state=42,n_j...
print('Top atributos por importância no teste (exploração após avaliação):',np.argsort(imp.i...
print('Matriz de confusão:\n',confusion_matrix(d,m.predict(b)))
```

Como interpretar

Os números são resultados específicos do experimento e da amostra, não garantias universais. Verifique o que mudou, qual método foi usado e qual é o cenário de aplicação. Compare com a teoria matemática e não confunda desempenho de treino, validação e teste.

4. Segundo experimento ou extensão controlada

Mude apenas uma condição principal (algoritmo, parâmetro ou tipo de dado), quando possível, e registre o efeito. Não ajuste decisões com base no teste final.

5. Exercício resolvido

Enunciado: reforce o conceito central com um exemplo menor, cujo resultado pode ser inspecionado diretamente.

6. Interpretação, limitações e erros comuns

Perguntas de revisão:
• Qual hipótese implícita sustenta o procedimento usado?
• Que erro de implementação ou de validação poderia tornar o resultado artificialmente otimista?
• Como você mudaria o experimento para refletir dados reais?

Risco metodológico

Uma explicação de modelo não prova causalidade. Compare estabilidade das importâncias, repita avaliações e registre limites da população e do período estudados.

7. Consulta rápida

• Interpretabilidade ≠ causalidade; descrever dataset, população e limitações.
• Fixar seeds, salvar métricas, registrar versões e origem dos dados.
• Model card básico: alvo, dados, métricas, subgrupos, limitações e uso indevido.
• Não publicar credenciais, dados restritos ou modelos binários não auditados.

Prática orientada e critérios de avaliação

Exercício A — sensibilidade: altere um hiperparâmetro/hipótese e apresente uma tabela pequena com resultados e explicação. Exercício B — revisão crítica: construa um exemplo de uso incorreto (sem aplicá-lo a dados reais) e explique o procedimento correto. Exercício C — comunicação: escreva um parágrafo sobre escopo, métricas, suposições e limitações do método.

Critério de aprovação: códigos executam do começo ao fim, não há seleção pelo teste final e cada resultado possui interpretação.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: interpretação fora da amostra. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema interpretação fora da amostra pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando um parâmetro por vez. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Laboratório adicional — Permutation importance com conjunto independente

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para interpretação fora da amostra sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

Síntese de verificação

Verifique se a divisão dos dados representa a aplicação, se pré-processamento e seleção foram ajustados apenas no treino e se as métricas são compatíveis com o custo de erro. Registre sementes, versões e limitações. Nenhuma pontuação obtida em amostra didática garante desempenho em outro contexto.

Documentação técnica

scikit-learn: https://scikit-learn.org/stable/ ; NumPy: https://numpy.org/doc/ ; SciPy: https://docs.scipy.org/doc/scipy/ ; Jupyter: https://jupyter.org/ .

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/