Bag-of-Words, TF-IDF e N-gramas

Receita 01 · Bag-Of-Words

RECEITA 01

Bag-of-Words

```
from sklearn.feature_extraction.text import CountVectorizer
corpus = ['gosto de dados','dados e modelos']
v = CountVectorizer()
X = v.fit_transform(corpus)
print(v.get_feature_names_out(), X.toarray())
```

USO RÁPIDO

Rode o bloco inteiro. Ajuste textos, parâmetros e corpus; compare com o guia técnico e verifique as pré-condições antes de interpretar a saída.

RECEITA 02

TF-IDF e bigramas

```
from sklearn.feature_extraction.text import TfidfVectorizer
v = TfidfVectorizer(ngram_range=(1,2),min_df=1)
X = v.fit_transform(['dados abertos','dados seguros'])
print(v.get_feature_names_out(), X.shape)
```

USO RÁPIDO

Os resultados são exemplos locais e sintéticos. Uma boa execução não garante desempenho com dados novos nem a disponibilidade de modelos externos.

OBSERVAÇÕES DIRETAS

ATENÇÃO

Ajuste o vocabulário somente no treino; n-gramas capturam contexto local, mas ampliam dimensão. TF-IDF não representa semântica por si só.

ANTES DE COPIAR

Verifique imports, idioma do corpus, pré-requisitos e variáveis utilizadas. Os blocos são independentes salvo indicação explícita.

INTERPRETAÇÃO

Compare com baseline; observe formas, valores, limites e possíveis erros metodológicos.

AMBIENTE

As receitas de spaCy requerem a instalação do modelo pt_core_news_sm. Exemplos locais não chamam API externa.

Cheat Sheet • Código para copiar e adaptar, com exemplos didáticos e limites explícitos.