Fundamentos de PLN e Linguística Computacional

Receita 01 · Contar Tokens Simples

RECEITA 01

Contar tokens simples

```
textos = ['Banco de dados', 'Banco do parque']
for texto in textos:
    print(len(texto.split()), texto)
```

USO RÁPIDO

Rode o bloco inteiro. Ajuste textos, parâmetros e corpus; compare com o guia técnico e verifique as pré-condições antes de interpretar a saída.

RECEITA 02

Contar documentos

```
from collections import Counter
corpus = ['sol e chuva', 'sol e vento']
print(Counter(' '.join(corpus).split()))
```

USO RÁPIDO

Os resultados são exemplos locais e sintéticos. Uma boa execução não garante desempenho com dados novos nem a disponibilidade de modelos externos.

OBSERVAÇÕES DIRETAS

ATENÇÃO

Um mesmo termo pode ter significados diferentes; a tokenização com split é apenas aproximação. Estabeleça tarefa, idioma, corpus e critérios de avaliação.

ANTES DE COPIAR

Verifique imports, idioma do corpus, pré-requisitos e variáveis utilizadas. Os blocos são independentes salvo indicação explícita.

INTERPRETAÇÃO

Compare com baseline; observe formas, valores, limites e possíveis erros metodológicos.

AMBIENTE

As receitas de spaCy requerem a instalação do modelo pt_core_news_sm. Exemplos locais não chamam API externa.