Tokenização e Normalização de Textos

Receita 01 · Tokenizar Preservando Pontuação

RECEITA 01

Tokenizar preservando pontuação

```
import re
texto = 'Olá! Como vai?'
tokens = re.findall(r'\w+|[^\w\s]', texto)
print(tokens)
```

USO RÁPIDO

Rode o bloco inteiro. Ajuste textos, parâmetros e corpus; compare com o guia técnico e verifique as pré-condições antes de interpretar a saída.

RECEITA 02

Normalização controlada

```
import unicodedata
texto = 'Coração MAIÚSCULO'
normal = unicodedata.normalize('NFC', texto).lower()
print(normal)
```

USO RÁPIDO

Os resultados são exemplos locais e sintéticos. Uma boa execução não garante desempenho com dados novos nem a disponibilidade de modelos externos.

OBSERVAÇÕES DIRETAS

ATENÇÃO

Stopwords e normalização devem respeitar domínio e tarefa. Compare formas originais e normalizadas antes de remover informação.

ANTES DE COPIAR

Verifique imports, idioma do corpus, pré-requisitos e variáveis utilizadas. Os blocos são independentes salvo indicação explícita.

INTERPRETAÇÃO

Compare com baseline; observe formas, valores, limites e possíveis erros metodológicos.

AMBIENTE

As receitas de spaCy requerem a instalação do modelo pt_core_news_sm. Exemplos locais não chamam API externa.

Cheat Sheet • Código para copiar e adaptar, com exemplos didáticos e limites explícitos.