# Transformers, Atenção e BERT

Receita 01 · Softmax Estável

## RECEITA 01

### Softmax estável

```
import numpy as np
x = np.array([1.0,2.0,3.0]); z=x-x.max()
a = np.exp(z)/np.exp(z).sum()
print(a, a.sum())
```

**USO RÁPIDO**

Rode o bloco inteiro. Ajuste textos, parâmetros e corpus; compare com o guia técnico e verifique as pré-condições antes de interpretar a saída.

## RECEITA 02

### Atenção didática

```
import numpy as np
Q=np.array([[1.,0.],[0.,1.]])
K=Q.copy(); V=np.array([[2.,1.],[1.,3.]])
S=Q@K.T/np.sqrt(Q.shape[1]); E=np.exp(S-S.max(axis=1,keepdims=True))
print((E/E.sum(axis=1,keepdims=True))@V)
```

**USO RÁPIDO**

Os resultados são exemplos locais e sintéticos. Uma boa execução não garante desempenho com dados novos nem a disponibilidade de modelos externos.

## OBSERVAÇÕES DIRETAS

**ATENÇÃO**

O cálculo local da atenção ilustra pesos e combinações, mas não constitui execução de BERT. Atenção, isoladamente, não prova explicabilidade.

**ANTES DE COPIAR**

Verifique imports, idioma do corpus, pré-requisitos e variáveis utilizadas. Os blocos são independentes salvo indicação explícita.

**INTERPRETAÇÃO**

Compare com baseline; observe formas, valores, limites e possíveis erros metodológicos.

**AMBIENTE**

As receitas de spaCy requerem a instalação do modelo pt_core_news_sm. Exemplos locais não chamam API externa.

Cheat Sheet • Código para copiar e adaptar, com exemplos didáticos e limites explícitos.