EP / DATA SCIENCE KNOWLEDGE BASE



02 / PROCESSAMENTO DE LINGUAGEM NATURAL

GUIA TÉCNICO / ESTUDO INDEPENDENTE

Textos, Expressões Regulares e Limpeza

MAPA DE ESTUDO

01 Fundamentos e objetivo

02 Modelo e escolhas metodológicas

03 Receitas Python reproduzíveis

04 Interpretação e limitações

05 Exercícios de aplicação

06 Checklist de qualidade

Conteúdo didático autoral — notas técnicas e exemplos independentes.
Material de apoio histórico não é reproduzido neste PDF.

01 | O problema e seu contexto

Textos, Expressões Regulares e Limpeza é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

Limpeza agressiva pode apagar negação, pontuação relevante, números e identificadores. Use regex específicas, testadas em amostras representativas.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Limpar e estruturar textos sem perder informações necessárias.
- Construir funções reprodutíveis com regex.
- Testar casos especiais em português.

Fundamentos conceituais

Expressões regulares reconhecem padrões de caracteres, mas não interpretam o significado de um documento. Para datas, números, emails e pontuação, defina explicitamente quais elementos devem permanecer. A normalização deve ter objetivos mensuráveis. Minúsculas podem ajudar em certas tarefas, mas podem prejudicar reconhecimento de entidades.

Modelo matemático e interpretação

Uma transformação de texto $T: \Sigma \rightarrow \Sigma$ transforma cadeias de símbolos; normalmente T não é inversível. Isso significa perda de informação, que deve ser justificada. Em classificação, a transformação aplicada em treino e inferência deve ser idêntica.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

Evite remover acentos sem motivo; CPF, emails e identificadores podem ser sensíveis. Regex não substitui parsers linguísticos. Escreva testes para pontuação, espaços e caracteres Unicode.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

Laboratório adicional — Regex: diferença entre encontrar e validar

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

03 | Cookbook Python

Limpeza sem perder acentos

```
import re
texto = 'Preço: R$ 120,00!'
limpo = re.sub(r'\s+', ' ', texto).strip()
print(limpo)
```

Localizar padrões

```
import re
texto = 'Pedido AB-124 e CD-981'
print(re.findall(r'[A-Z]{2}-\d{3}', texto))
```

04 | Interpretação e limites

Limpeza agressiva pode apagar negação, pontuação relevante, números e identificadores. Use regex específicas, testadas em amostras representativas.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/