EP / DATA SCIENCE KNOWLEDGE BASE



05 / PROCESSAMENTO DE LINGUAGEM NATURAL

GUIA TÉCNICO / ESTUDO INDEPENDENTE

Reconhecimento de Entidades Nomeadas

MAPA DE ESTUDO

01 Fundamentos e objetivo

02 Modelo e escolhas metodológicas

03 Receitas Python reproduzíveis

04 Interpretação e limitações

05 Exercícios de aplicação

06 Checklist de qualidade

Conteúdo didático autoral — notas técnicas e exemplos independentes.
Material de apoio histórico não é reproduzido neste PDF.

01 | O problema e seu contexto

Reconhecimento de Entidades Nomeadas é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

Entidades nem sempre correspondem a palavras isoladas. Verifique rótulos, fronteiras, ambiguidade e nomes não observados.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Entender NER, entidade e fronteiras de menções.
- Avaliar precisão e recall por entidade.
- Diferenciar heurísticas de modelos treinados.

Fundamentos conceituais

Reconhecimento de entidades nomeadas (NER/REN) tenta localizar menções como pessoas, organizações e localidades e atribuir um tipo. A simples presença de letra maiúscula não basta: início de frase e nomes próprios coexistem. Em extração de informação, erros de fronteira podem ser tão graves quanto erros de classificação.

Modelo matemático e interpretação

Precisão = TP/(TP+FP) e recall = TP/(TP+FN) para uma política definida de comparação das entidades previstas e anotadas. Em correspondência exata, início, fim e tipo devem concordar.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

Não confiar em regex como sistema de NER de propósito geral. Em documentação real, considerar confidencialidade e dados pessoais.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

03 | Cookbook Python

Extrair entidades com spaCy

```
import spacy
nlp = spacy.load('pt_core_news_sm')
doc = nlp('Maria visitou São Paulo.')
print([(e.text,e.label_) for e in doc.ents])
```

Padrão conservador com regex

```
import re
texto = 'Pedido 203 entregue em 12/08/2026'
print(re.findall(r'\b\d{2}/\d{2}/\d{4}\b', texto))
```

04 | Interpretação e limites

Entidades nem sempre correspondem a palavras isoladas. Verifique rótulos, fronteiras, ambiguidade e nomes não observados.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/