EP / DATA SCIENCE KNOWLEDGE BASE



06 / PROCESSAMENTO DE LINGUAGEM NATURAL

GUIA TÉCNICO / ESTUDO INDEPENDENTE

Bag-of-Words, TF-IDF e N-gramas

MAPA DE ESTUDO

01 Fundamentos e objetivo

02 Modelo e escolhas metodológicas

03 Receitas Python reproduzíveis

04 Interpretação e limitações

05 Exercícios de aplicação

06 Checklist de qualidade

Conteúdo didático autoral — notas técnicas e exemplos independentes.
Material de apoio histórico não é reproduzido neste PDF.

01 | O problema e seu contexto

Bag-of-Words, TF-IDF e N-gramas é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

Ajuste o vocabulário somente no treino; n-gramas capturam contexto local, mas ampliam dimensão. TF-IDF não representa semântica por si só.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Construir matrizes documento-termo.
- Comparar contagem, TF-IDF e n-gramas.
- Interpretar esparsidade e importância local de termos.

Fundamentos conceituais

Bag-of-Words ignora a ordem global e usa frequências de termos; n-gramas recuperam dependências locais ao custo de maior dimensionalidade. TF-IDF reduz o peso de termos presentes em muitos documentos, mas isso não implica compreensão semântica. A frequência depende da preparação e do vocabulário fixado no treino.

Modelo matemático e interpretação

Uma forma comum de IDF suavizado é idf(t)=log((1+n)/(1+df(t)))+1. O peso TF-IDF é a frequência do termo multiplicada pela importância inversa do documento, com variantes de normalização.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

O vectorizer deve ser ajustado apenas com o conjunto de treinamento. Em inferência, termos desconhecidos não devem alterar o vocabulário já aprendido.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

Laboratório adicional — Vocabulario aprendido exclusivamente no treino

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

03 | Cookbook Python

Bag-of-Words

```
from sklearn.feature_extraction.text import CountVectorizer
corpus = ['gosto de dados','dados e modelos']
v = CountVectorizer()
X = v.fit_transform(corpus)
print(v.get_feature_names_out(), X.toarray())
```

TF-IDF e bigramas

```
from sklearn.feature_extraction.text import TfidfVectorizer
v = TfidfVectorizer(ngram_range=(1,2),min_df=1)
X = v.fit_transform(['dados abertos','dados seguros'])
print(v.get_feature_names_out(), X.shape)
```

04 | Interpretação e limites

Ajuste o vocabulário somente no treino; n-gramas capturam contexto local, mas ampliam dimensão. TF-IDF não representa semântica por si só.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/