EP / DATA SCIENCE KNOWLEDGE BASE



08 / PROCESSAMENTO DE LINGUAGEM NATURAL

GUIA TÉCNICO / ESTUDO INDEPENDENTE

Sumarização por Frequência e Luhn

MAPA DE ESTUDO

01 Fundamentos e objetivo

02 Modelo e escolhas metodológicas

03 Receitas Python reproduzíveis

04 Interpretação e limitações

05 Exercícios de aplicação

06 Checklist de qualidade

Conteúdo didático autoral — notas técnicas e exemplos independentes.
Material de apoio histórico não é reproduzido neste PDF.

01 | O problema e seu contexto

Sumarização por Frequência e Luhn é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

A heurística de Luhn neste notebook é aproximação didática. Extração preserva frases originais, mas pode perder contexto e ressalvas.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Implementar sumarização extrativa por frequência.
- Compreender a heurística de Luhn e suas limitações.
- Preservar a ordem original das frases selecionadas.

Fundamentos conceituais

Sumarização extrativa escolhe frases existentes no documento, em contraste com uma sumarização abstrativa que produz frases novas. Métodos de frequência priorizam sentenças com termos salientes. A heurística clássica de Luhn usa proximidade de palavras significativas; neste capítulo implementamos uma aproximação pedagógica explícita, não uma reprodução literal de todas as variantes históricas.

Modelo matemático e interpretação

Um score simples é S(s)=Σ_{t em s} f(t) / |s|. Para uma janela de Luhn, uma pontuação típica é (nº de termos significativos)² / (extensão da janela), que favorece concentração.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

A extrativa pode copiar informações irrelevantes ou perder ressalvas. Avaliar cobertura de ideias, fidelidade e redundância; não interpretar ranking como garantia de qualidade.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

03 | Cookbook Python

Sumarizar por frequência

```
import re
from collections import Counter
texto = 'Dados ajudam. Dados são úteis. Sol brilha.'
frases = re.split(r'(?<=[.!?])\s+', texto)
freq = Counter(re.findall(r'\w+',texto.lower()))
scores = [sum(freq[t] for t in re.findall(r'\w+', s.lower())) for s in frases]
print(frases[max(range(len(scores)), key=scores.__getitem__)])
```

Score Luhn aproximado

```
def luhn(pos):
    return len(pos)**2 / (pos[-1]-pos[0]+1) if pos else 0
print(luhn([1,3,4]))
```

04 | Interpretação e limites

A heurística de Luhn neste notebook é aproximação didática. Extração preserva frases originais, mas pode perder contexto e ressalvas.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/