EP / DATA SCIENCE KNOWLEDGE BASE



13 / PROCESSAMENTO DE LINGUAGEM NATURAL

GUIA TÉCNICO / ESTUDO INDEPENDENTE

Modelos de Linguagem e Geração

MAPA DE ESTUDO

01 Fundamentos e objetivo

02 Modelo e escolhas metodológicas

03 Receitas Python reproduzíveis

04 Interpretação e limitações

05 Exercícios de aplicação

06 Checklist de qualidade

Conteúdo didático autoral — notas técnicas e exemplos independentes.
Material de apoio histórico não é reproduzido neste PDF.

01 | O problema e seu contexto

Modelos de Linguagem e Geração é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

Modelos de n-gramas ajudam a compreender geração probabilística; não reproduzem o desempenho de LLMs. Controle sementes e discuta alucinação.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Entender previsão do próximo token e temperatura.
- Construir gerador probabilístico elementar e reproduzível.
- Distinguir geração linguística de veracidade factual.

Fundamentos conceituais

Um modelo de linguagem autoregressivo estima a distribuição do próximo token condicionada ao prefixo. Temperatura altera a concentração da distribuição de amostragem: temperaturas baixas privilegiam tokens mais prováveis, sem tornar o texto necessariamente verdadeiro. Contexto máximo, tokenização, amostragem e instruções influenciam a geração. Grandes modelos possuem treinamento e alinhamento adicionais que não são reproduzidos neste laboratório.

Modelo matemático e interpretação

$P(w_1,\ldots,w_n)=\prod_i P(w_i \mid w_1,\ldots,w_{i-1})$. Na amostragem, $p_i(T)=\mathrm{softmax}(\mathrm{logits}_i/T)$, para $T>0$.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

O gerador local demonstrativo é um modelo de bigramas, não um LLM. Não enviar dados privados a APIs externas sem autorização; serviços externos podem implicar custos e limites.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

03 | Cookbook Python

Próximo token por contagem

```
from collections import Counter,defaultdict
tokens = 'a ciência usa dados a ciência usa modelos'.split()
trans = defaultdict(Counter)
for a,b in zip(tokens,tokens[1:]):trans[a][b]+=1
print(trans['usa'].most_common(2))
```

04 | Interpretação e limites

Modelos de n-gramas ajudam a compreender geração probabilística; não reproduzem o desempenho de LLMs. Controle sementes e discuta alucinação.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/