EP / DATA SCIENCE KNOWLEDGE BASE



14 / PROCESSAMENTO DE LINGUAGEM NATURAL

GUIA TÉCNICO / ESTUDO INDEPENDENTE

Sentence Embeddings e Busca Semântica

MAPA DE ESTUDO

01 Fundamentos e objetivo

02 Modelo e escolhas metodológicas

03 Receitas Python reproduzíveis

04 Interpretação e limitações

05 Exercícios de aplicação

06 Checklist de qualidade

Conteúdo didático autoral — notas técnicas e exemplos independentes.
Material de apoio histórico não é reproduzido neste PDF.

01 | O problema e seu contexto

Sentence Embeddings e Busca Semântica é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

Busca com TF-IDF/SVD é aproximação local; não alegue ter executado sentence-transformers sem instalar e carregar um modelo real.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Contrastar recuperação lexical e semântica.
- Ilustrar embeddings de frases de maneira reprodutível.
- Criar interface opcional com Sentence Transformers.

Fundamentos conceituais

Embeddings de frases condensam informação de uma sequência em um vetor para busca por similaridade. A recuperação semântica pode aproximar paráfrases, mas também produzir falsos positivos. Neste núcleo obrigatório, utilizamos projeção densa de TF-IDF apenas como demonstração geométrica; ela NÃO equivale a um encoder neural de sentenças. O laboratório opcional descreve modelos Sentence Transformers.

Modelo matemático e interpretação

Uma consulta vetorial q e documentos d_i podem ser ranqueados por sim(q,d_i). O índice de busca deve preservar dimensão, normalização e modelo de embedding para todos os registros.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

Não misturar embeddings produzidos por modelos distintos. Registre versão do modelo, idioma, licença e metadados das fontes. Pesos neurais não são baixados durante a execução padrão.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

03 | Cookbook Python

Busca vetorial local (SVD)

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.decomposition import TruncatedSVD
from sklearn.metrics.pairwise import cosine_similarity
docs = ['pln trabalha com textos','sql consulta tabelas','nlp usa vetores']
v=TfidfVectorizer(); X=v.fit_transform(docs); q=v.transform(['textos'])
svd=TruncatedSVD(n_components=2,random_state=42)
print(cosine_similarity(svd.fit_transform(X),svd.transform(q)))
```

04 | Interpretação e limites

Busca com TF-IDF/SVD é aproximação local; não alegue ter executado sentence-transformers sem instalar e carregar um modelo real.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/