GUIA TÉCNICO

Retrieval-Augmented Generation (RAG)

Propósito — Conteúdo didático autoral — notas técnicas e exemplos independentes. Material de apoio histórico não é reproduzido neste PDF.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

ROTEIRO DO DOCUMENTO

1. Fundamentos e objetivo
2. Modelo e escolhas metodológicas
3. Receitas Python reproduzíveis
4. Interpretação e limitações
5. Exercícios de aplicação
6. Checklist de qualidade

01 | O problema e seu contexto

Retrieval-Augmented Generation (RAG) é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

O notebook implementa recuperação e resposta apoiada em trechos, não geração por LLM externo. Exiba fontes e recuse resposta quando não houver evidência.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Explicar ingestão, divisão em trechos e recuperação.
- Montar RAG lexical sem chamadas a API.
- Distinguir evidência recuperada de resposta gerada.

Fundamentos conceituais

Retrieval-Augmented Generation (RAG) combina recuperação de documentos com geração condicionada a evidências. Um sistema robusto deve registrar fontes, identificar quando faltam evidências e não interpretar todo texto recuperado como instrução confiável. A demonstração obrigatória é somente recuperação com resposta baseada em trechos literais — sem LLM externo.

Modelo matemático e interpretação

O recuperador ranqueia trechos c_i com score $\text{sim}(q,c_i)$; o gerador condicionado estima $P(\text{resposta} \mid \text{pergunta, trechos selecionados})$. A qualidade do sistema depende das duas etapas, que devem ser avaliadas separadamente.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

Citações devem apontar para documentos reais. Não usar conteúdo não confiável recuperado para alterar instruções do assistente; evitar exposição de fontes confidenciais. Trechos pequenos podem quebrar contexto, e grandes podem reduzir relevância.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

Laboratório adicional — RAG: evidência antes da redação

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

03 | Cookbook Python

Recuperar evidência TF-IDF

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity
docs=['Biblioteca abre às 8 horas.','Laboratório tem computadores.']
v=TfidfVectorizer(); X=v.fit_transform(docs)
s=cosine_similarity(v.transform(['horas biblioteca']),X).ravel()
print(docs[s.argmax()] if s.max()>0.1 else 'Sem evidência')
```

Citação de fonte

```
docs = [('doc01','Abre às 8h.'),('doc02','Fecha às 18h.')]
print({'fonte':docs[0][0], 'trecho':docs[0][1]})
```

04 | Interpretação e limites

O notebook implementa recuperação e resposta apoiada em trechos, não geração por LLM externo. Exiba fontes e recuse resposta quando não houver evidência.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/